



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Facultat d'Informàtica de Barcelona



GENERACIÓN DE DATOS ARTIFICIALES PARA MODELOS DE APRENDIZAJE PROFUNDO EN IMAGEN MÉDICA

POL CASACUBERTA GIL

Director/a: JAVIER BÉJAR ALONSO (Departamento de Ciencias de la Computación)

Titulación: Grado en Ingeniería Informática (Computación)

Memoria del trabajo de fin de grado

Facultat d'Informàtica de Barcelona (FIB)

Universitat Politècnica de Catalunya (UPC) - BarcelonaTech

25/01/2024

Abstract

This project focuses on the reasearch and development of generative models for image-to-image translation, with an emphasis on improving the training of models for polyp detection in colonoscopies. The challenge in addressing such medical problems often lies in the limitations of the datasets, which typically suffer from scarcity and insufficient diversity.

The goal has been to leverage the potential of generative models to create realistic synthetic data that can complement and enhance existing datasets to address their limitations. For this, LDPolypVideo dataset was used, a compilation of colonoscopy videos accompanied by annotations that serve as a basis for training detection models.

Object detection, specifically of polyps, has been done before, but this work has sought to improve the accuracy with which polyps are detected, avoiding false positives and false negatives, thus improving the reliability of the diagnosis.

Furthermore, the project has explored various techniques and approaches in the realm of image generation and object detection, to identify the most effective methodologies in the context of medical imaging. The expected result is an advancement in the accuracy and reliability of polyp detection models.

Keywords: Machine learning, Computer vision, Generative models, image-to-image translation.

Resumen

Este proyecto se centra en la investigación y el desarrollo de modelos generativos para la traducción de imagen a imagen, con el enfoque en mejorar el entrenamiento de modelos para la detección de pólipos en colonoscopias. El desafío al abordar este tipo de problemas médicos suelen ser las limitaciones de los conjuntos de datos, que a menudo sufren de escasez y diversidad insuficiente.

El objetivo ha sido aprovechar el potencial de los modelos generativos para crear datos sintéticos realistas que puedan complementar y mejorar los conjuntos de datos existentes para abordar sus limitaciones. Para esto, se utilizó el conjunto de datos LDPolypVideo, una compilación de videos de colonoscopias acompañado de anotaciones que sirven de base para el entrenamiento de los modelos de detección.

La detección de objetos, en concreto de pólipos, ya se ha hecho con anterioridad, pero en este trabajo se ha buscado mejorar la precisión con la que se detectan los pólipos, evitando falsos positivos y falsos negativos, mejorando así la fiabilidad del diagnóstico.

Además, el proyecto ha explorado diversas técnicas y enfoques en el ámbito de la generación de imágenes y en la detección de objetos, para identificar las metodologías más efectivas en el contexto de las imágenes médicas. El resultado esperado es un avance en la precisión y fiabilidad de los modelos de detección de pólipos.

Palabras clave: Aprendizaje automático, Visión por computador, Modelos generativos, traducción de imagen a imagen.

Índice general

1. Alcance y contexto	6
1.1. Introduccion	6
1.2. Contexto	7
1.2.1. Centrar el proyecto en el marco de la FIB	7
1.2.2. Definición de conceptos	7
1.2.3. Identificación del problema a resolver	10
1.2.4. Actores implicados	10
1.3. Justificación	11
1.4. Alcance	11
1.4.1. Objetivos del proyecto	11
1.4.2. Identificar otros requerimientos funcionales o no funcionales	12
1.4.3. Obstáculos y riesgos	13
1.5. Metodología y rigor	14
1.5.1. Metodología	14
1.5.2. Metodología del desarrollo de código	15
1.5.3. Desviaciones de la metodología inicial	15
2. Planificación	17
2.1. Descripción de las tareas	17
2.1.1. GP - Gestión del proyecto	17
2.1.2. FT - Fase de documentación y aprendizaje	19
2.1.3. FP - Fase de Diseño y Desarrollo de modelos	20
2.1.4. Documentación del proyecto	22
2.1.5. Recursos	23
2.2. Estimaciones	24
2.3. Gantt	26
2.4. Gestión del riesgo: Planes alternativos y obstáculos	28
2.4.1. Retraso en el Tiempo en la ejecución de tareas	28
2.4.2. Desafíos en la segmentación de Pólipos	28
2.4.3. Generación de Datos sintéticos insuficientemente realistas	28
2.4.4. Enfermedad	29
2.5. Desviaciones de la planificación	29

3. Gestión económica (presupuesto)	30
3.1. Identificación de los costes	30
3.1.1. Costos de personal	30
3.1.2. Costes generalmente calculados	33
3.1.3. Contingencias	35
3.2. Control de gestión	36
4. Sostenibilidad y compromiso social	37
4.1. Informe de sostenibilidad	37
4.1.1. Autoevaluación	37
4.1.2. Impacto ambiental	38
4.1.3. Impacto económico	40
4.1.4. Impacto social	43
4.2. Integración de conocimientos	45
4.3. Identificación de leyes y regulaciones	46
5. Red de Segmentación	48
5.1. Modelos elegidos	48
5.1.1. FastRcnn / FasterRCNN	48
5.1.2. SSD	51
5.1.3. RetinaNet / Detectron	52
5.2. Métricas de evaluación	54
5.3. Optimización de hiperparámetros	54
5.3.1. ¿Qué es Optuna?	55
5.3.2. RayTune	56
5.4. Automatización	57
5.4.1. Proceso automatizado de evaluación de modelos	57
5.5. Prueba y Visualización de modelos	58
5.6. Preparación del dataset	59
5.6.1. Carga del dataset	59
5.7. Entrenamiento de los modelos	60
5.7.1. Configuración del modelo	60
5.7.2. Entrenamiento	61
5.7.3. Validación	62
5.7.4. Manejo personalizado de batches	63
5.7.5. Carga y Guardado de los modelos	64
6. Red de Aumentación de Datos	66
6.1. Modelos	66
6.1.1. CycleGAN	66
6.1.2. Pix2PixHD	67
6.1.3. SPADE	69
6.2. Entrenamiento	71
6.3. Preparación de los datos	71
6.3.1. Creación de máscaras	71
6.3.2. Transformación de directorios	72

6.4. Generación de datos	75
6.5. Problemas de convergencia	76
6.5.1. Mode collapse	76
7. Análisis del dataset	78
7.1. Análisis de las cajas delimitadoras	78
7.1.1. Implementación del análisis de datos	78
7.1.2. Resultados del análisis	81
8. Análisis y Resultados Experimentales	87
8.1. Detección	87
8.2. Aumentación de datos	93
9. Conclusiones	96
9.1. Conocimientos adquiridos	96
9.2. Resultados del proyecto	97
9.3. Limitaciones del estudio	97
9.4. Reflexiones finales	97
10.Trabajo Futuro	98

Índice de cuadros

2.1. Tabla de tareas con su tiempo y sus dependencias	25
3.1. Sueldos por hora para cada rol	30
3.2. Costos humanos para cada tarea	31
3.3. Coste para cada tarea	32
3.4. Costes por cada rol	33
3.5. Costos materiales	33
3.6. Costos de entrenamiento	34
3.7. Costes genéricos	34
3.8. Costes aplicando contingencia	35
3.9. Costes de imprevistos conocidos	35
3.10. Coste total	36

Índice de figuras

1.1.	Diagrama de los componentes de un VAE.	8
1.2.	Diagrama de los componentes de una GAN.	9
1.3.	Resumen de los diferentes tipos de modelos generativos incluidos los modelos de diffusion.	10
2.1.	Diagrama de gantt de la planificación temporal.	27
5.1.	FastRCNN	49
5.2.	FasterRCNN	50
5.3.	Region Proposal Network	51
5.4.	Comparación entre dos diagramas de disparo único, SSD y YOLO	52
5.5.	Diagrama de la arquitectura de RetinaNet	53
6.1.	Diagrama del funcionamiento de CycleGAN	67
6.2.	Diagrama de la arquitectura del generador de Pix2PixHD	68
6.3.	Diagrama del funcionamiento de pix2pixHD	69
6.4.	Diagrama de la arquitectura de SPADE	70
6.5.	Normalización SPADE vs. tradicional	71
7.1.	Método del codo	82
7.2.	Análisis de silueta	83
7.3.	Centros de 3 clusters	84
7.4.	Centros de 8 clusters	84
7.5.	Cajas delimitadoras con 3 clusters	84
7.6.	Cajas delimitadoras con 8 clusters	84
7.7.	Gráfico de densidad de cajas delimitadoras	85
7.8.	Gráfico de densidad de cajas delimitadoras con 3 clusters	86
7.9.	Gráfico de densidad de cajas delimitadoras con 8 clusters	86
8.1.	Detección de pólipos en colonoscopia	87
8.2.	Detección de pólipos en colonoscopia	87
8.3.	Resultados del entrenamiento de la red CycleGAN	95

Capítulo 1

Alcance y contexto

1.1. Introduccion

La detección temprana de anomalías o características dentro de imágenes es una tarea crítica en diversos campos, desde la imagen médica hasta la visión por computador y más allá. En este contexto, el desarrollo y la exploración de modelos generativos basados en la traducción de imagen a imagen han surgido como un enfoque poderoso para abordar este desafío. Este proyecto tiene como objetivo investigar y desarrollar modelos de aprendizaje profundo generativos para la traducción de imagen a imagen, con un enfoque en su aplicación a conjuntos de datos, donde la generación de datos sintéticos puede mejorar el entrenamiento de modelos de aprendizaje profundo para diversas tareas.

La traducción de imagen a imagen se refiere al proceso de transformar una imagen de un dominio o estilo en otro, preservando al mismo tiempo las características esenciales e información. Esta técnica versátil ha encontrado aplicaciones en numerosos campos. Un ejemplo destacado de ello es la transferencia de estilo artístico, tal como se presenta en el trabajo de Jing et al. [8]. Además, también se ha utilizado en la mejora de la resolución de imágenes, como se discute en [11], y en la restauración de imágenes, entre otros usos.

Al aprovechar las capacidades de los modelos generativos, podemos generar datos sintéticos que complementan conjuntos de datos existentes, abordando así limitaciones relacionadas con la escasez, diversidad o calidad de los datos.

En este caso, utilizaremos el conjunto de datos LDPolypVideo [13], que consiste en videos de colonoscopias y contiene máscaras que serán utilizadas para entrenar los modelos.

La segmentación de imágenes en concreto de pólipos ya se ha hecho con anterioridad, en este trabajo se buscará mejorar la precisión con la que se detectan los pólipos, evitando falsos positivos y falsos negativos. También se investigarán las diferentes posibles soluciones al problema de la generación de imagen y se probarán de forma empírica para determinar que soluciones funcionan mejor.

En las secciones siguientes, profundizaremos en los objetivos específicos y las

metodologías de esta iniciativa de investigación.

1.2. Contexto

1.2.1. Centrar el proyecto en el marco de la FIB

Este trabajo de fin de grado de Ingeniería informática se sitúa en el marco de la Facultad de informática de Barcelona de la Universidad Politécnica de Cataluña y está dirigido por Javier Béjar Alonso. Esta investigación también se enmarca dentro del BSC en el grupo de investigación HPAI.

1.2.2. Definición de conceptos

Datos artificiales

Para abordar un problema de segmentación de imágenes necesitamos un dataset anotado, en cuyo caso las imágenes del dataset deben ser anotadas manualmente, conseguir que esta segmentación manual sea perfecta a nivel de pixel para tantas imágenes no es tarea fácil, suele ser un trabajo muy costoso. Cuál es la solución? Ahí es donde entra la síntesis de datos artificiales. Generamos mediante diferentes tipos de técnicas unos datos parecidos a los originales, pero suficientemente diferentes como para que se mejore la robustez de nuestra red de segmentación de imágenes. [16]

A continuación hablaremos de algunas arquitecturas que se pueden usar para generar imágenes sintéticas.

VAE

Las estructuras Variational auto-encoding se han usado con éxito para segmentar imágenes, como se hace en UNet-eVAE [15].

Un VAE es una red neuronal que usamos para aprender y generar datos como imágenes o texto. El objetivo principal del VAE es capturar y modelar una distribución de probabilidad usando los datos en la entrada, generando con estos datos otros nuevos que sean similares a la entrada.




Figura 1.1: Diagrama de los componentes de un VAE.

*Fuente: By EugenioTL - Own work, CC BY-SA 4.0,
<https://commons.wikimedia.org/w/index.php?curid=107231104>*

Componentes del VAE:

- Encoder o *Approximate Posterior*: En la primera parte de un VAE, llamada codificación, se toma una entrada y se mapea a un espacio latente, es decir, una representación en baja dimensión que captura las características importantes de los datos.
- Espacio latente: Este espacio latente se corresponde con los parámetros de una distribución variacional, de esta manera el encoder puede producir diferentes muestras que provienen de la misma distribución.
- Decoder: Esta parte del VAE tiene la función opuesta al Encoder, mapea desde el espacio latente al espacio del input para producir datos.

Ambas redes se entrenan de forma conjunta utilizando el truco de la reparametrización. Se explica con más detalle en [9].

GAN

Las Redes Generativas Adversarias o GAN, son una clase de modelos de aprendizaje automático utilizados en el aprendizaje no supervisado. Fueron introducidas por Ian Goodfellow [1].

Las GAN están compuestas de dos redes neuronales: el Generador y el Discriminador, que se entrenan generalmente de forma alterna, durante unas Epochs, se entrena el Generador y en otras el Discriminador.




Figura 1.3: Resumen de los diferentes tipos de modelos generativos incluidos los modelos de diffusion.

Fuente: [18]

1.2.3. Identificación del problema a resolver

El proyecto se inicia con la identificación de un problema que se abordará utilizando modelos generativos de traducción de imagen a imagen. En este contexto, el problema identificado es la limitación de datos de entrenamiento de alta calidad y diversidad, esta situación suele ser común en el campo médico, ya que obtener datos resulta costoso debido a cuestiones como la privacidad y los gastos asociados con la obtención de datos anotados. Incluso cuando contamos con datos anotados, a menudo los profesionales de la salud se enfrentan a dificultades para emitir diagnósticos precisos en ciertos casos.

Este proyecto se enfocará en desarrollar y evaluar modelos generativos, eficientes y efectivos para resolver estos desafíos en un contexto específico, lo que contribuirá a abordar un problema común en diversas áreas de la inteligencia artificial y la ciencia de datos.

1.2.4. Actores implicados

- **Estudiante investigador:** el estudiante que realiza el proyecto es un stakeholder clave, ya que su trabajo conllevará aprender sobre una variedad de disciplinas a lo largo del proyecto.
- **Director del trabajo:** Es quien supervisa y guía al estudiante en el proyecto, este también es esencial en el proyecto. Su experiencia y orientación afectará en el desarrollo y la calidad del proyecto.
- **Universidad:** A la institución académica le es de su interés que los proyectos llevados a cabo por los alumnos tengan éxito, ya que contribuyen a la reputación de la misma.

- Comunidad científica: Otros investigadores y académicos en el campo de la informática, la visión por computador y la inteligencia artificial son stakeholders relevantes. Los avances y descubrimientos que surgen del proyecto pueden contribuir al conocimiento.
- Pacientes: Dado que estamos tratando con aplicaciones del ámbito médico, los pacientes o la población se pueden beneficiar de las mejoras en detección de enfermedades, como la detección temprana de pólipos, estos son stakeholders cruciales.
- Profesionales de la Salud: Los médicos y profesionales de la salud que utilizan las herramientas basadas en el proyecto para mejorar el diagnóstico, son stakeholders importantes. El buen rendimiento de estas herramientas de diagnóstico puede mejorar la calidad de la atención médica.

1.3. Justificación

La elección de entrenar nuestras propias Redes neuronales en el Barcelona SuperComputing Center (BSC) utilizando el dataset proporcionado, se basa en una evaluación específica de las necesidades y objetivos de nuestro proyecto.

En el ámbito de la generación de imágenes médicas, los requisitos de precisión y especificidad son críticos. Las redes generativas preentrenadas pueden ser una opción viable, pero al diseñar y entrenar nuestras propias redes generativas, tenemos un mayor control sobre la adaptación de los modelos a las características únicas de nuestro conjunto de datos. Un ejemplo de redes generativas preentrenadas son las que brindan medigan [19] con redes preentrenadas para segmentar pólipos.

Entrenar nuestras propias redes generativas nos permite personalizar los modelos para satisfacer las demandas específicas de nuestro proyecto. Podemos ajustar la arquitectura de las redes, los hiperparámetros y las técnicas de entrenamiento para optimizar la generación de imágenes médicas de alta calidad. El dataset en cuestión puede tener características particulares que requieran una adaptación cuidadosa. Entrenar nuestras propias redes generativas en el BSC nos brinda la potencia de cálculo necesaria para abordar estos desafíos. Otro factor a tener en cuenta es la propiedad intelectual. Entrenar nuestras propias redes generativas nos otorga la propiedad intelectual completa.

1.4. Alcance

1.4.1. Objetivos del proyecto

- Segmentar los pólipos de las imágenes.
- Crear una interfaz gráfica

Subobjetivos

- Escoger métricas de evaluación.
- Ajustar hiperparámetros.
- Diseñar la arquitectura de la red neuronal.
- Entrenar una red neuronal que segmente los pólipos de las imágenes.
- Entrenar una red neuronal que genere datos artificiales.
- Entrenar una red neuronal con los datos artificiales y los reales.
- Entrenar una red neuronal con los datos artificiales.
- Reajustar la red neuronal entrenada con los datos reales solo con datos artificiales.
- Reajustar la red neuronal entrenada con los datos reales con una combinación de datos artificiales y reales.
- Entrenar una red con datos artificiales y ajustar la red con datos reales.
- Usar modelos que generan directamente tanto imágenes como mascararas.

1.4.2. Identificar otros requerimientos funcionales o no funcionales

Requerimientos funcionales

- Captura de datos de Video: el sistema debe ser capaz de recibir y procesar videos de colonoscopias como entrada.
- Segmentación de imágenes: El sistema debe ser capaz de segmentar las imágenes de los videos para identificar áreas relevantes.
- Generación de informes: El sistema debe ser capaz de generar informes que evalúen la calidad de las segmentaciones.
- Interfaz de Usuario: El sistema debe tener una interfaz de usuario que permita interactuar con él de manera intuitiva.
- Documentación: Debe proporcionarse documentación detallada para usuarios y profesionales médicos.

Requerimientos no funcionales

- Eficiencia Computacional.
- Escalabilidad: Si se prevé el uso en el futuro, es posible que haya la necesidad de gestionar un volumen más grande de datos de entrenamiento.
- Robustez: Establecer la capacidad del modelo para afrontar situaciones inesperadas o ataques adversos como la manipulación de los datos de entrada para estimular las neuronas de tal manera que se obtengan resultados diferentes a los que esperaríamos con el input dado. Por ejemplo, en un modelo para segmentar pólipos en imágenes, un atacante podría camuflar pólipos en las imágenes para que no sean detectados o perturbar una imagen donde no hay pólipos con perturbaciones imperceptibles para los humanos, pero que el modelo detecte que hay pólipos.
- Tiempo de inferencia.
- Documentación y mantenimiento.
- Identificar y definir los posibles obstáculos y riesgos.
- Explorar y seleccionar las arquitecturas de los modelos que se adapten mejor al problema que se está tratando.
- Los tiempos de entrenamiento de los datos pueden llegar a ser prohibitivos debido a la gran cantidad de datos y a la complejidad de las arquitecturas.
- Colaboración interdisciplinaria.

1.4.3. Obstáculos y riesgos

Obstáculos técnicos

- Mode collapse, es un problema común cuando entrenamos (GANs) y se refiere a cuando la red produce un número limitado o similar de outputs, esto suele suceder cuando la parte generadora de la red produce un resultado realista, puede ser que este aprenda a producir outputs iguales o similares a ese para engañar al discriminador.
- La selección de los hiperparámetros puede ser complicada y puede dar a entrenamientos ineficientes y rendimientos deficientes.
- Tiempos de entrenamiento prolongados: Los modelos generativos a menudo requieren tiempos de entrenamiento largos, especialmente en conjuntos de datos grandes, lo que puede ser costoso en términos de tiempo, y recursos computacionales.

Obstáculos Médicos

- Regulaciones Médicas: Se deben cumplir con regulaciones médicas y de privacidad de datos. Cumplir con estas regulaciones puede ser un desafío.

Riesgos de Ética y privacidad

- Privacidad de los Pacientes: La gestión de datos médicos sensibles debe cumplir con los estándares éticos y de privacidad de datos.
- Sesgo y Equidad: Los modelos de aprendizaje profundo pueden tener sesgos inherentes. Identificar y mitigar el sesgo es esencial para garantizar la equidad en la detección.

Riesgos de Evaluación de resultados

- Errores de Falsos Positivos/Negativos: Los errores en la detección de pólipos pueden tener graves implicaciones médicas. Reducir estos errores es importante.
- Sobreajuste de los modelos: El modelo podría sobreajustarse a los datos de entrenamiento y no generalizar bien a nuevos datos.
- Métricas inadecuadas: Utilizar métricas inadecuadas para evaluar la calidad de las generaciones puede llevar a conclusiones erróneas sobre el rendimiento del modelo.
- Interpretabilidad: Interpretar, explicar los resultados de los modelos generativos no es trivial, entender qué características está buscando el modelo para discriminar el resultado puede ser difícil.

Riesgos de Recursos

- Tiempo: el tiempo requerido para completarse el proyecto se podría prolongar.

1.5. Metodología y rigor

1.5.1. Metodología

El desarrollo de este trabajo va a estar basado en gran parte a una investigación empírica donde se van a probar un gran número de arquitecturas, hiperparámetros y metodologías para atacar el problema en cuestión para posteriormente evaluar cuáles son las mejores configuraciones. Por este motivo y por ser un proyecto de un solo autor, se va a utilizar una metodología ágil que va a permitir modificar el plan de trabajo, en concreto se va a utilizar Kanban. El Kanban típicamente consiste en tres columnas:

- To-do: Tareas que hay que hacer, pero que aún no han empezado.
- En progreso: Son las tareas en las que se está trabajando de forma activa.
- Done: Cuando una tarea en progreso se acaba, se mueve a esta columna.

La idea principal del Kanban es visualizar las tareas y limitar la cantidad de trabajo en progreso.

Además, se programarán entrevistas semanales con el director del proyecto para evaluar el trabajo hecho durante la semana y hablar sobre la dirección que tiene que tomar el trabajo.

1.5.2. Metodología del desarrollo de código

Para llevar un control de versiones del código que se va generando durante el curso del proyecto se va a usar Git, un software ya muy conocido para controlar los cambios en el código de forma cómoda y eficiente.

El código que se va generando, para ser más fácilmente accesible y para evitar imprevistos con el disco local, se va a subir a un repositorio en el servicio web GitHub.

En cuanto al flujo de trabajo que se va a utilizar, será el Git Flow, donde hay las siguientes ramas:

- Master: Contiene el código en producción. Todo el código de desarrollo se fusiona en esta rama en algún momento a través de las releases.
- Develop: Contiene el código en preproducción, cuando se quiere finalizar un feature, se fusiona con esta rama.
- Feature: Por cada tarea que se realiza, se crea una nueva rama para trabajar en ella. Esta rama parte de develop.
- Hotfix: Se encarga de corregir una incidencia. Parte de develop.
- Releases: Parte de develop. Se fusionará con la rama master.

Con el objetivo de ser pragmáticos se usarán principalmente las ramas master y develop, ya que al ser una única persona en el proyecto será más ágil.

1.5.3. Desviaciones de la metodología inicial

En el transcurso de este proyecto, se ha llevado a cabo una revisión periódica de la metodología adoptada, con especial atención en la metodología Kanban para la gestión de tareas y el modelo Git Flow para el control de versiones, especialmente útil dado que en ocasiones necesito trabajar desde distintos ordenadores. Tras una evaluación, se ha confirmado que no ha sido necesario implementar cambios en estas metodologías ya que han demostrado ser eficaces y adecuadas para las necesidades y los objetivos del proyecto.

La metodología Kanban, con su enfoque en la visualización de tareas y la limitación del trabajo en progreso, ha demostrado ser una herramienta indispensable para la gestión eficiente del proyecto. Esta metodología ha permitido una buena organización y priorización de tareas, crucial dado el carácter individual del proyecto. La capacidad de adaptar rápidamente el flujo de trabajo a las necesidades cambiantes y la facilidad de identificar y abordar los cuellos de

botella han sido aspectos importantes de esta metodología. En concreto, ha ayudado a mitigar los retrasos en la disponibilidad de la cuenta del BSC para poder entrenar modelos de redes neuronales, para poder así verificar la corrección del código escrito.

En lo que respecta al desarrollo de código, Git Flow ha seguido siendo una metodología de control de versiones muy eficaz. Con su estructura clara y su enfoque en la organización han facilitado la gestión y documentación de los cambios en el código de manera ordenada y coherente. Esta continuidad ha sido vital para evitar confusiones y errores, especialmente en un proyecto donde la autogestión es clave.

La decisión de mantener estas metodologías ha sido una muestra de la importancia de elegir herramientas adecuadas desde el inicio del proyecto. Esta continuidad metodológica no solo ha contribuido a la eficiencia del trabajo, sino que también ha permitido una mayor concentración en los aspectos técnicos y creativos del proyecto, en lugar de tener que adaptarse a nuevas estructuras de trabajo.

Capítulo 2

Planificación

Se ha previsto que el total del proyecto debería suponer unas 540 horas, 30 horas por cada ECTS. El inicio del TFG ha empezado el día 7 de septiembre, coincidiendo con el primer día de clases de la universidad. La fecha final no es muy clara, ya que solo se tiene conocimiento de la fecha de lectura del TFG que se realizará el 22 de enero, por lo tanto, se calcula que la entrega de la documentación será alrededor del día 8 de enero y se fija como fecha final. Si contamos los días que tenemos disponibles desde el día 7 de septiembre hasta el 8 de enero, disponemos de 137 días en total, incluidos fines de semana. Si repartimos las 540 horas que sabemos tenemos que dedicar, aproximadamente deberemos dedicar diariamente 4 horas. A la semana esto equivale a 28 horas semanales.

2.1. Descripción de las tareas

Esta sección proporciona una visión general de las tareas y fases clave del proyecto. Está dividida en las siguientes secciones principales.

- GP: Gestión del proyecto
- FT: Fase teórica
- FP: Fase práctica
- DP: Documentación del proyecto

2.1.1. GP - Gestión del proyecto

Esta sección aborda aspectos clave relacionados con la gestión general del proyecto, incluyendo el alcance, la planificación, el presupuesto y otros aspectos importantes para su éxito.

- **Duración:** 68 h
- **Dependencias:** -

GP.1 - Alcance

En esta fase, se define claramente los objetivos y limitaciones del proyecto. Esto incluye especificar qué se hará y qué no se hará en el proyecto. El alcance ayuda a evitar desviaciones y garantiza que el proyecto se mantenga enfocado en sus metas.

- **Duración:** 18 h
- **Dependencias:** -

GP.2 - Planificación

Aquí se desarrolla un plan detallado para todo el proyecto. Esto incluye la programación de tareas, la asignación de recursos, la identificación de riesgos y la definición de hitos importantes. Un plan sólido sirve como hoja de ruta para el desarrollo del proyecto.

- **Duración:** 12 h
- **Dependencias:** GP.1

GP.3 - Presupuesto

En esta sección, se detalla el presupuesto necesario para llevar a cabo el proyecto. Esto implica estimar los costos relacionados con recursos humanos, equipos, software y otros gastos. El presupuesto es esencial para asegurarse de que el proyecto sea financieramente viable.

- **Duración:** 14 h
- **Dependencias:** GP.2

GP.4 - Informe de sostenibilidad

Un informe de sostenibilidad evalúa el impacto ambiental y social del proyecto. Puede incluir consideraciones sobre el uso eficiente de recursos, la gestión de residuos y el cumplimiento de estándares éticos. Esto es relevante, especialmente en proyectos relacionados con la salud y la tecnología.

- **Duración:** 14 h
- **Dependencias:** GP.3

GP.5 - Reuniones

Consiste en una serie de reuniones con el director del proyecto para asegurarse de que el proyecto sigue el rumbo correcto, solventar posibles dudas y mantener informado al director sobre el estado actual del proyecto.

- **Duración:** 10 h
- **Dependencias:** -

2.1.2. FT - Fase de documentación y aprendizaje

La fase teórica se dedica a la investigación y el aprendizaje previo al desarrollo práctico del proyecto. Esto incluye la adquisición de conocimientos de PyTorch, el estudio del estado del arte y la elección de las métricas de evaluación.

- **Duración:** 163.5 h
- **Dependencias:** -

FT.1 - Aprendizaje de PyTorch

Esta etapa se centra en el aprendizaje del framework PyTorch. Habrá que familiarizarse con la sintaxis, las herramientas y las técnicas necesarias para implementar modelos de aprendizaje profundo utilizando PyTorch.

- **Duración:** 17.5 h
- **Dependencias:** -

FT.2 - Estudio del Estado-del-arte

Investigar los modelos de aprendizaje profundo que se han utilizado con éxito en tareas de detección de objetos y segmentación de imágenes médicas.

- **Duración:** 50 h
- **Dependencias:** -

FT.3 - Estudio de las complicaciones al entrenar los modelos

A la hora de entrenar los modelos como por ejemplo una red GAN pueden surgir una serie de problemas, en esta fase nos centraremos en estudiar las complicaciones que pueden surgir y estudiar sus posibles soluciones.

- **Duración:** 10.5 h
- **Dependencias:** -

FT.4 - Elección de Métricas de evaluación

Aquí se seleccionarán las métricas de evaluación para medir el rendimiento de los modelos. Estas métricas son puntos críticos para determinar el buen funcionamiento de nuestros modelos.

- **Duración:** 7 h
- **Dependencias:** -

FT.5 - Diseño del Modelo de detección

En esta etapa, se planificará y diseñará la arquitectura del modelo de detección de pólipos.

- **Duración:** 34 h
- **Dependencias:** FT.2

FT.6 - Diseño del Modelo de aumentación de datos

En esta otra etapa, se planificará y diseñará la arquitectura del modelo aumentación de datos. Esto incluye decidir la estructura de la red, las capas y las funciones de activación que se van a utilizar.

- **Duración:** 34 h
- **Dependencias:** 10.5

FT.7 - Estimación del tiempo de Entrenamiento

Aquí se calculará el tiempo estimado que tomará el proceso de entrenamiento de los modelos. Esto es esencial para una planificación adecuada.

- **Duración:** 10.5 h
- **Dependencias:** FT.5, FT.6

2.1.3. FP - Fase de Diseño y Desarrollo de modelos

La fase práctica se centra en la implementación y desarrollo de modelos de detección de pólipos en colonoscopias. Esto incluye el preprocesamiento de datos, la implementación en PyTorch de modelos de segmentación, optimización, evaluación, implementación de modelos de aumentación de datos, experimentación y conclusiones finales.

- **Duración:** 229.8 h
- **Dependencias:** -

FP.1 - Preprocesamiento de los datos

Esta fase se enfoca en la preparación de tus datos de entrada para el entrenamiento de modelos. Incluye tareas como la carga de videos.

- **Duración:** 7 h
- **Dependencias:** -

FP.2 - Implementación de un modelo de segmentación

Durante esta etapa, se traducirá el diseño del modelo en código. Esto implica definir la estructura de la red, las capas y las funciones de pérdida.

- **Duración:** 30 h
- **Dependencias:** -

FP.2.1 - Ajuste y Optimización

Aquí ajustaremos el modelo de segmentación, realizando ajustes en la arquitectura o los hiperparámetros para mejorar el rendimiento.

- **Duración:** 50 h
- **Dependencias:** -

FP.2.2 - Evaluación del modelo

Esta sección se dedica a evaluar el modelo de segmentación a partir de las métricas seleccionadas para medir su eficacia.

- **Duración:** 10 h
- **Dependencias:** -

FP.3 - Implementación del modelo de aumentación de datos

Aquí se desarrollará un modelo de aumentación de datos que aumentará la diversidad y cantidad de los datos de entrenamiento.

- **Duración:** 31.2 h
- **Dependencias:** FP.2, FP.2.1, FP.2.2

FP.3.1 - Ajuste y Optimización

Aquí ajustaremos el modelo de aumentación de datos, realizando ajustes en la arquitectura o los hiperparámetros para mejorar el rendimiento.

- **Duración:** 50 h
- **Dependencias:** -

FP.3.2 - Evaluación del modelo

Esta sección se dedica a evaluar el modelo de aumentación de datos a partir de las métricas seleccionadas para medir su eficacia.

- **Duración:** 9.6 h
- **Dependencias:** -

FP.4 - Guardado de modelos

Aquí se describirá cómo guardar y gestionar los modelos entrenados para su posterior uso.

- **Duración:** 2 h
- **Dependencias:** -

FP.5 - Experimentación

Aquí se llevarán a cabo experimentos para probar diferentes enfoques, hiperparámetros y configuraciones con el objetivo de mejorar el rendimiento de los modelos

- **Duración:** 40 h
- **Dependencias:** FP.3, FP.3.1, FP.3.2

2.1.4. Documentación del proyecto

La documentación de un proyecto es esencial, aquí se describen los subapartados relacionados con la documentación del proyecto.

DP.1 - Documentación

Esta sección se refiere a la creación y el mantenimiento de documentos relacionados con el proyecto. Esto incluye el diseño del modelo de detección, los resultados del entrenamiento, los informes de evaluación y cualquier otra información relevante. La documentación es crucial para la trazabilidad y la replicabilidad del proyecto.

- **Duración:** 43.7 h
- **Dependencias:** -

DP.2 - Conclusiones

Esta sección resumirá las lecciones aprendidas, los resultados obtenidos y las conclusiones finales del proyecto, incluyendo posibles áreas de mejora y recomendaciones para proyectos futuros.

- **Duración:** 10 h
- **Dependencias:** FP.5

DP.3 - Presentación

En este apartado, se establecen las pautas para la presentación de resultados y hallazgos del proyecto. Esto puede incluir la preparación de informes finales o presentaciones visuales.

- **Duración:** 15 h
- **Dependencias:** -

DP.4 - Lectura

Esta fase implica la exposición oral y la defensa del proyecto ante un tribunal, un público especializado y expertos en el campo de estudio.

- **Duración:** 10 h
- **Dependencias:** -

2.1.5. Recursos

En esta sección se detallan los recursos necesarios para la ejecución exitosa del proyecto. Aquí se describen los recursos humanos, materiales y software que se utilizarán en el proyecto.

Recursos humanos

Dado que este proyecto se realiza por una sola persona, todos los roles los va a asumir la misma persona, los roles son los siguientes:

- **Gestor de proyecto:** Persona encargada de la gestión del proyecto: la planificación, asignación de recursos y supervisión del proyecto
- **Investigador:** Responsable de la investigación y desarrollo de modelos de aprendizaje profundo.
- **Ingeniero de software:** Encargado de implementar el código
- **Equipo de comunicación y Presentación:** Responsables de la presentación del proyecto y sus resultados.

Recursos materiales

- **Portátil:** Destinado a tareas como la documentación, el desarrollo del código y demás.
- **Tablet:** Usada para leer documentación y hacer apuntes.
- **BSC:** El Barcelona SuperComputing Center contiene la capacidad de computación para acelerar el entrenamiento de modelos de aprendizaje profundo.

Recursos software

- Overleaf: Usado para escribir la documentación en formato LaTeX en la nube.
- GanttProject: Se usa para crear el diagrama de gantt.
- GitHub: Usado para almacenar el código y mantener un control de versiones.
- GitHub Projects: Usado para implementar la tabla Kanban, ya que con su integración con GitHub, podemos trabajar más cómodamente en un solo entorno de trabajo.
- PyCharm: Será el editor de código escogido para implementar nuestros modelos en Python.
- Google Drive: Ocasionalmente, se utilizarán los servicios de Google para almacenar ciertos archivos o software de la Suite de Google como Google Docs, Google Sheets o Google Slides.

2.2. Estimaciones

Para realizar el cálculo de las horas se han establecido una serie de supuestos:

- Cada día se va a dedicar 4 horas a realizar el TFG, incluidos fines de semana.
- El TFG se empieza el día 7 de septiembre.
- La entrega de la documentación se hace el 8 de enero.
- La lectura del TFG se realiza el 22 de enero.
- Disponemos, por tanto, de 137 días, $137 \text{ días} * 4 \text{ horas} \approx 540$
- El cálculo de las horas debería rondar las 540 horas, por los créditos que tiene asignado, aunque en la práctica puede que se le dediquen más horas.

Con estas premisas podemos hacer una serie de cálculos haciendo una estimación de los porcentajes de nuestro tiempo que se van a dedicar a cada tarea.

ID	Task	Time(h)	Dependencias	Recursos
GP	Gestión del proyecto	68.00	-	Portátil
GP.1	Alcance	18.00	-	Portátil
GP.2	Planificación	12.00	GP.1	Portátil
GP.3	Presupuesto	14.00	GP.2	Portátil
GP.4	Informe de sostenibilidad	14.00	GP.3	Portátil
GP.5	Reuniones	10.00	-	-
FT	Fase teórica	163.50	-	Tablet
FT.1	Aprendizaje de pytorch	17.50	-	Portátil
FT.2	Estudio del estado-del-arte	50.00	-	Tablet
FT.3	Estudio de las complicaciones al entrenar modelos	10.50	-	Tablet
FT.4	Elección de métricas	7.00	-	Tablet
FT.5	Diseño del modelo de detección	34.00	FT.2	Portátil
FT.6	Diseño del modelo de aumentación de datos	34.00	FT.2	Portátil
FT.7	Estimación del tiempo de entrenamiento	10.50	FT.5, FT.6	Portátil
FP	Fase práctica	229.80	-	Portátil
FP.1	Preprocesamiento de los datos	7.00	-	Portátil
FP.2	Implementación de un modelo de segmentación	30.00	-	Portátil, BSC
FP.2.1	Ajuste y optimización	50.00	-	Portátil, BSC
FP.2.2	Evaluación del modelo	10.00	-	Portátil, BSC
FP.3	Implementación del modelo de aumentación	31.20	FP.2, FP.2.1, FP.2.2	Portátil, BSC
FP.3.1	Ajuste y optimización	50.00	-	Portátil, BSC
FP.3.2	Evaluación del modelo	9.60	-	Portátil, BSC
FP.4	Guardado de modelos	2.00	-	Portátil, BSC
FP.5	Experimentación	40.00	FP.3, FP.3.1, FP.3.2	Portátil, BSC
DP	Documentación del proyecto	78.70	-	Portátil
DP.1	Documentación	43.70	-	Portátil
DP.2	Conclusiones	10.00	FP.5	Portátil
DP.3	Presentación	15.00	DP.2	Portátil
DP.4	Lectura	10.00	-	Portátil
	TOTAL	540.00	-	

Cuadro 2.1: Tabla de tareas con su tiempo y sus dependencias

2.3. Gantt

El objetivo de incluir un diagrama de Gantt en la documentación es ofrecer una representación visual del cronograma del proyecto. En este diagrama se muestran las tareas, sus duraciones y las dependencias entre ellas a lo largo del tiempo. Los diferentes colores indican diferentes grupos de tareas. El software con el que se ha creado el diagrama no permite activar y desactivar tareas de forma intermitente, pero la idea de las reuniones es hacer una cada dos semanas.




Figura 2.1: Diagrama de gantt de la planificación temporal.

2.4. Gestión del riesgo: Planes alternativos y obstáculos

2.4.1. Retraso en el Tiempo en la ejecución de tareas

- Descripción: El tiempo necesario para cada tarea podría ser mayor de lo anticipado. Esto podría retrasar el cronograma general del proyecto y afectar a la entrega.
- Mitigación: Para mitigar este riesgo se ha creado un plan de contingencia para las tareas más importantes, la implementación y el ajuste de ambos modelos. En caso de retrasarse alguna de estas tareas o bien si durante la fase teórica se prevé que ajustar los modelos va a tomar más tiempo del asignado, se puede acotar la fase teórica en hasta un período de 20 horas, además se pueden asignar hasta 18 horas semanales adicionales durante las asignadas en la planificación de las implementaciones (8 horas más durante los fines de semana y dos horas diarias más entre semana). Este plan de contingencia debería ser más que suficiente para afrontar posibles imprevistos.

2.4.2. Desafíos en la segmentación de Pólipos

- Descripción: La segmentación precisa de los pólipos en las imágenes puede ser difícil debido a la variabilidad en su apariencia.
- Mitigación: Investigar y ajustar los modelos según sea necesario. Hemos añadido tareas que estudian las complicaciones que puede haber al entrenar modelos para solucionar-los, por este motivo.

2.4.3. Generación de Datos sintéticos insuficientemente realistas

- Descripción: La red neuronal que genera datos sintéticos podría producir imágenes o vídeos que no sean lo suficientemente realistas o representativos. Esto podría llevar a un sesgo en el conjunto de datos sintéticos y podría no generalizar bien en situaciones del mundo real.
- Mitigación: Para tratar este riesgo, es importante validar los datos generados por la red neuronal. Los datos generados tienen que ser coherentes con las colonoscopias reales, Si se encuentran resultados muy distintos, se deben ajustar los hiperparámetros de generación o añadir más datos reales al conjunto de entrenamiento para mantener la representatividad. Como ya hemos dicho, hemos añadido tareas que se centran al estudio de las posibles complicaciones que puede haber y que métodos hay para intentar solucionarlas.

2.4.4. Enfermedad

- Descripción: Existe el riesgo de que me pueda enfermar lo que podría tener un impacto significativo en el progreso y la ejecución del proyecto. La enfermedad puede variar en gravedad y duración.
- Mitigación: Flexibilidad en el cronograma, el hecho de incluir márgenes de tiempo adicionales para acomodar posibles retrasos o la reestructuración de tareas.

2.5. Desviaciones de la planificación

Debido a retrasos en la disponibilidad de la cuenta del Barcelona SuperComputing Center (BSC) para entrenar los modelos, se ha ajustado la planificación del proyecto. Las tareas de evaluación, ajuste y optimización de los modelos de detección de pólipos se han pospuesto. En su lugar, se han adelantado otras tareas para mantener el progreso del proyecto. Entre estas se incluye la implementación de modelos de aumentación y el análisis de datos para generar un conjunto de datos de aumentación coherente.

En resumen, hemos reorganizado el cronograma de trabajo, sustituyendo unas tareas por otras. Además, hemos intensificado las horas dedicadas a la documentación para asegurar avances significativos en el proyecto y evitar retrasos.

Capítulo 3

Gestión económica (presupuesto)

3.1. Identificación de los costes

3.1.1. Costos de personal

Para este proyecto se ha determinado que van a ser necesarios 4 roles para llevarse a cabo. Un gestor de proyecto, encargado de asignar tareas y todo aquello relacionado con la planificación. Un Investigador, encargado de ahondar en el estado del arte y realizar los diseños que va a tener que implementar el Ingeniero de Software. Y por último, vamos a necesitar un Técnico de comunicación que lleve a cabo los recursos necesarios para la presentación de las ideas principales de este proyecto y la Lectura de este.

Los sueldos anuales brutos se han obtenido a partir de [21]. Los costos de personal se calculan dados los sueldos medios brutos anuales, estos se pasan a través de la calculadora de sueldo neto [27] que nos da las cuotas a la Seguridad Social y las retenciones de IRPF, si restamos esto al sueldo, obtenemos el sueldo neto.

Rol	Sueldo bruto (€/h)	Sueldo neto (€/h)
Gestor de proyecto	20.98	15.73
Investigador (data scientist)	21.89	16.32
Ingeniero de software	20.98	15.73
Técnico de comunicación	17.06	13.16

Cuadro 3.1: Sueldos por hora para cada rol

Vamos a utilizar la siguiente nomenclatura para los roles:

- GP: Gestor de proyecto

- I: Investigador
- IS: Ingeniero de software
- TC: Técnico de comunicación

A continuación se muestra una tabla con la asignación de horas del rol para cada tarea.

Tarea	Horas	GP	I	IS	TC
Gestión del proyecto	68.00	-	-	-	-
Alcance	18.00	18.00	0.00	0.00	0.00
Planificación	12.00	12.00	0.00	0.00	0.00
Presupuesto	14.00	14.00	0.00	0.00	0.00
Informe de sostenibilidad	14.00	14.00	0.00	0.00	0.00
Reuniones	10.00	10.00	0.00	0.00	0.00
Fase teórica	163.50	-	-	-	-
Aprendizaje de pytorch	17.50	0.00	0.00	17.50	0.00
Estudio del estado-del-arte	50.00	0.00	50.00	0.00	0.00
Estudio de las complicaciones al entrenar modelos	10.50	0.00	10.50	0.00	0.00
Elección de métricas	7.00	0.00	7.00	0.00	0.00
Diseño del modelo de detección	34.00	0.00	34.00	0.00	0.00
Diseño del modelo de aumentación de datos	34.00	0.00	34.00	0.00	0.00
Estimación del tiempo de entrenamiento	10.50	0.00	10.50	0.00	0.00
Fase práctica	229.80	-	-	-	-
Preprocesamiento de los datos	7.00	0.00	0.00	7.00	0.00
Implementación de un modelo de segmentación	30.00	0.00	0.00	30.00	0.00
Ajuste y optimización	50.00	0.00	0.00	50.00	0.00
Evaluación del modelo	10.00	0.00	0.00	10.00	0.00
Implementación del modelo de aumentación	31.20	0.00	0.00	31.20	0.00
Ajuste y optimización	50.00	0.00	0.00	50.00	0.00
Evaluación del modelo	9.60	0.00	0.00	9.60	0.00
Guardado de modelos	2.00	0.00	0.00	2.00	0.00
Experimentación	40.00	0.00	0.00	40.00	0.00
Documentación del proyecto	78.70	-	-	-	-
Documentación	43.70	0.00	43.70	0.00	0.00
Conclusiones	10.00	0.00	10.00	0.00	0.00

Cuadro 3.2: Costos humanos para cada tarea

Conociendo las horas asignadas a los roles para cada tarea, podemos calcular el coste de esa tarea, teniendo en cuenta solamente el coste por hora de cada rol. En otras palabras, solamente teniendo en cuenta el coste personal.

Tarea	Coste Tarea €
Gestión del proyecto	-
Alcance	377.71
Planificación	251.81
Presupuesto	293.78
Informe de sostenibilidad	293.78
Reuniones	209.84
Fase teórica	-
Aprendizaje de pytorch	367.22
Estudio del estado-del-arte	1094.46
Estudio de las complicaciones al entrenar modelos	229.84
Elección de métricas	153.22
Diseño del modelo de detección	744.23
Diseño del modelo de aumentación de datos	744.23
Estimación del tiempo de entrenamiento	229.84
Fase práctica	-
Preprocesamiento de los datos	146.89
Implementación de un modelo de segmentación	629.52
Ajuste y optimización	1049.21
Evaluación del modelo	209.84
Implementación del modelo de aumentación	654.71
Ajuste y optimización	1049.21
Evaluación del modelo	201.45
Guardado de modelos	41.97
Experimentación	839.37
Documentación del proyecto	-
Documentación	956.56
Conclusiones	218.89
Presentación	255.85
Lectura	170.57

Cuadro 3.3: Coste para cada tarea

También es interesante ver el coste de cada rol. Nótese que la suma de los costes de todos los roles, es la misma que la suma de los costes de todas las tareas.

Rol	Horas	Coste (€)
GP	68.00	1426.92
I	199.70	4371.26
IS	247.30	5189.38
TC	25.00	426.41
TOTAL:	540.00	11413.98

Cuadro 3.4: Costes por cada rol

3.1.2. Costes generalmente calculados

Costes materiales: Amortizaciones

Para llevar a cabo el proyecto se van a utilizar principalmente dos dispositivos, un portátil Asus para trabajar fuera de casa y un ordenador de sobremesa. El ordenador de sobremesa está compuesto por un iMac, un ratón Logitech, un Teclado Custom y unos auriculares Bose para escuchar videos sobre el estado del arte y también para reproducir las clases grabadas. Aparte, para leer documentación y tomar notas se va a utilizar un iPad con sus respectivos accesorios. El software utilizado es gratuito y en la mayor parte, de código abierto, por lo tanto, el software no tiene coste alguno. Para calcular las amortizaciones se ha tenido en cuenta [22]. La fórmula que se va a usar para calcular la amortización va a ser la siguiente:

$$A = \frac{C}{V * D * H} * T \quad (3.1)$$

Dónde las variables son:

- Coste = C
- Vida útil = V
- Días de trabajo al año = D
- Horas por día = H
- Total de horas dedicadas = T

Elemento	Precio (€)	Amortización(€)
Ordinador Imac 24'	1650.00	256.88
Ipad + accessoris	868.00	135.13
Logitech Mx master 3	115.00	17.90
Portátil Asus 560	740.00	115.20
Auriculares Bose	300.00	46.70
Teclado Custom	120.00	18.68

Cuadro 3.5: Costos materiales

Costes computacionales

Para calcular los costes de entrenar los modelos, tanto la energía utilizada y el coste de comprar las GPU. Lo calcularemos comparando los precios actuales de cloud computing con tarjetas gráficas de poder de cálculo similar a las que usaremos en el BSC, Usaremos los precios de Google Cloud con una tarjeta gráfica concreta, la Nvidia V100, que tiene un parecido razonable en términos de potencia de cálculo a la Radeon Instinct MI50, de las que se disponen en el BSC. El precio por hora por cada GPU Nvidia V100 es de 2,48 USD. El ratio de dólares a euros corresponde al actual en el momento del cálculo de este presupuesto.

Gráfica	USD/Hora	Horas	Coste USD	USD a EUR	Coste EUR
Nvidia V100	2.48	50.00	124.00	0.94	117.14

Cuadro 3.6: Costos de entrenamiento

Costes indirectos

- Electricidad: Un ordenador de sobremesa puede consumir unos 220 W en promedio, si lo utilizamos 4 horas al día el consumo será de 0.88 kWh. La energía se paga a 0.14€/kWh. Si lo calculamos nos da 0.1232 € cada día, si tenemos en cuenta el número de días del proyecto 137, el coste es de 16.87€ . [23]
- Transporte: La T-Jove cuesta 80€ al trimestre.
- Internet: El coste del internet es de 50€ al mes con la compañía O2.
- Alquiler: Un piso de 130 m² cuesta alrededor de 2000€ al mes en l'Eixample.
- Mantenimiento del espacio: La limpieza de casa tiene un coste de 15€ /h 3 h por semana.

Tipo de coste:	Costes Genéricos(€)
Amortizaciones	525.11
Electricidad	16.88
Transporte	106.67
Internet	200.00
Mantenimiento	880.71
Computación	117.14
Total:	1846.51

Cuadro 3.7: Costes genéricos

3.1.3. Contingencias

La contingencia es una reserva de fondos que establecemos para hacer frente a situaciones inesperadas que puedan surgir, a modo de margen de seguridad. Es algo común en la planificación de proyectos, ya que ayuda a mitigar el impacto negativo de sorpresas que amenacen el presupuesto original. Esta cantidad se suele expresar como un porcentaje, en nuestro caso usaremos un 30 %. Un valor generoso, ya que el resultar de un trabajo de investigación, no se sabe a priori, y con exactitud cuantas horas de cómputo vamos a necesitar, por ejemplo, para entrenar los modelos.

Tipo de coste	Coste (€)	Contingencia (%)	Contingencia (€)	Coste final (€)
CPA	11413.98	30.00	3424.19	14838.18
CG	1846.51	30.00	553.95	2400.46

Cuadro 3.8: Costes aplicando contingencia

También vamos a tener en cuenta en nuestro presupuesto, los posibles imprevistos que pueden acontecer, esto es, los costes de los imprevistos conocidos, ya que los costes de imprevistos que no conocemos no los podemos calcular. Por ejemplo, si se lanzara una ley de la metodología que se debe seguir para entrenar las redes para la protección de datos, esto podría retrasar el proyecto y aumentar el número de horas de este, aumentando el coste del proyecto. Pero esta casuística es algo inesperada, por lo tanto, no lo podemos tener en cuenta en el presupuesto. Las horas de retraso de las tareas se han calculado teniendo en cuenta el plan de contingencia explicado en la planificación, 18 horas semanales adicionales * 7 semanas aproximadamente. Estas horas se han repartido entre los desafíos en la segmentación, la generación de datos poco realista y el retraso de alguna otra tarea que se retrase en el tiempo en esta fase práctica.

Imprevisto	Horas	Coste (€)	Riesgo %	Coste imputado(€)
Retraso de las tareas	35.36	715.22	20.00	143.04
Desafíos en la segmentación	35.36	715.22	10.00	71.52
Generación de datos poco realista	70.71	1430.44	35.00	500.66
Enfermedad	15.00	303.43	5.00	15.17
Total	156.43	3164.32	70.00	730.39

Cuadro 3.9: Costes de imprevistos conocidos

A continuación podemos ver la suma final de todos los costes:

Fase	Coste (€)
PCA	11413.98
CG	1846.51
Contingencia	3978.15
Imprevistos	730.39
Total:	17969.03

Cuadro 3.10: Coste total

3.2. Control de gestión

El objetivo del control de gestión es comparar y evaluar las desviaciones entre el presupuesto y los costes reales, en nuestro caso vamos a tener en cuenta las siguientes desviaciones:

- **Desviación de horas por tarea (eficiencia):**
(horas estimadas - horas reales) * coste estimado
- **Desviación de coste por tarea (por tarifa):**
(coste estimado - coste real) * consumo horas real
- **Desviación de horas por Rol (eficiencia):**
(horas estimadas - horas reales) * coste estimado
- **Desviación de coste por Rol (por tarifa):**
(coste estimado - coste real) * consumo horas real
- **Desviación de coste de materiales:**
coste material estimado - coste material real
- **Desviación de coste de costes indirectos:**
costes indirectos estimados - costes indirectos reales
- **Desviación de coste de imprevistos:**
costes imprevistos estimados - costes imprevistos reales
- **Desviación de coste total:**
coste total estimado - coste total real

Capítulo 4

Sostenibilidad y compromiso social

4.1. Informe de sostenibilidad

4.1.1. Autoevaluación

Al completar la encuesta de autoevaluación y reflexionar sobre ella, he identificado algunas áreas de debilidad en mi conocimiento del tema. Una de las áreas es la comprensión de las métricas que describen el impacto social de los productos y soluciones. En esta área me siento cómodo abordando cuestiones relacionadas con la seguridad y la privacidad. Sin embargo, he notado que hay métricas relacionadas con el impacto social que no había considerado de inmediato. Esto indica una debilidad en mi capacidad para evaluar de manera exhaustiva el impacto social de mis proyectos.

En cuanto al impacto ambiental, reconozco que es un aspecto crucial en la actualidad, dada la situación crítica en la que nos encontramos en términos de cambio climático. Es esencial que consideremos cómo nuestras acciones y proyectos pueden contribuir al calentamiento global y otras problemáticas ambientales. No considerar estos aspectos sería éticamente cuestionable.

Un aspecto importante en este tipo de proyectos es la colaboración interdisciplinaria, y creo que este es uno de mis puntos fuertes, ya que en el pasado he tenido que trabajar con profesionales de otras disciplinas para llevar a cabo proyectos relacionados con la medicina.

Finalmente, la dimensión económica del proyecto es otra área en la que no había prestado mucha atención. Después de investigar más sobre este tema, veo que es fundamental comprender cómo las decisiones económicas pueden influir en el éxito o fracaso de un proyecto. Esto resalta una debilidad en mi comprensión de cómo gestionar eficazmente los aspectos económicos de mis proyectos.

Esta autoevaluación me ha recordado la importancia del aprendizaje continuo en mi desarrollo profesional. Debo estar dispuesto a aprender y mejorar en

estas áreas.

En resumen, mi autoevaluación me ha permitido identificar mis puntos fuertes, pero sobre todo mis carencias en este ámbito. Estoy comprometido a aprender y crecer en estas áreas para desarrollar proyectos más completos y éticos en el futuro.

4.1.2. Impacto ambiental

Respecto el proyecto puesto en producción, has estimado el impacto ambiental que tendrá la realización del proyecto? Te has planteado minimizar el impacto, por ejemplo, reutilizando recursos?

En un proyecto como este, es importante estimar el impacto ambiental. Esto puede incluir el consumo de energía durante el entrenamiento de modelos de aprendizaje profundo, la gestión de residuos electrónicos y el uso de recursos informáticos. A nivel del entrenamiento, es complicado estimar el coste por el hecho de ser un trabajo de investigación.

La minimización del impacto ambiental es importante, por este motivo se pueden tomar medidas para reducir el consumo de energía. Por ejemplo, la optimización de algoritmos y el uso eficiente de recursos computacionales.

Respecto la vida útil, como se resuelve el problema que se quiere abordar (estado del arte) y en que mejorará ambientalmente tu solución respecto a las existentes?

Actualmente, existen sistemas de apoyo a la decisión de los profesionales médicos basados en la visión por computador, pero todavía hay margen para mejorar en términos de precisión y eficiencia. Mi solución tiene el potencial de mejorar ambientalmente la detección de pólipos al reducir la necesidad de repeticiones innecesarias de colonoscopias o pruebas adicionales debido a falsos positivos o falsos negativos. Esto podría llevar a una disminución en la cantidad de recursos médicos utilizados, como, materiales y energía asociados con procedimientos médicos adicionales.

Has cuantificado el impacto ambiental de la realización del proyecto? ¿Qué medidas has tomado para reducir el impacto? ¿Has cuantificado esta reducción?

El impacto ambiental de un proyecto tecnológico, especialmente uno que implica un uso intensivo de recursos computacionales, es un aspecto importante a considerar. Aunque la cuantificación exacta del impacto ambiental puede ser compleja, se pueden tomar en cuenta varios factores:

- Consumo de energía en entrenamiento de modelos: el entrenamiento de modelos de aprendizaje profundo es una operación que consume una cantidad significativa de energía, especialmente cuando se utilizan GPUs de

alta potencia durante largos períodos. Se estimó el consumo energético basándose en las horas de entrenamiento y las especificaciones de la gráfica utilizada como referencia GPU Nvidia V100

- Uso de infraestructura de datos: La operación de servidores de datos y sistemas de almacenamiento también contribuyen al impacto ambiental.

La reducción, como ya hemos dicho, es difícil de cuantificar, pero el uso real de energía sí lo podemos calcular: sabiendo que el consumo de la gráfica promedio es de 250 Watts y ha estado operativa durante 288 horas, podemos saber que el gasto energético es de 72 kWh.

Medidas para reducir el Impacto Ambiental:

- Optimización de algoritmos: Mejorar la eficiencia de los algoritmos para reducir el tiempo de entrenamiento y, por ende, el consumo de energía.
- Uso de infraestructura Verde: Optar siempre por utilizar infraestructura de cómputo en la nube que emplea energías renovables o tiene políticas de sostenibilidad robustas.
- Eficiencia en el uso de Recursos: Planificar cuidadosamente el uso de recursos computacionales para evitar operaciones innecesarias.

Si hicieras de nuevo el proyecto, podrías realizarlo con menos recursos?

Existen enfoques que podrían reducir el uso de recursos, por ejemplo:

- Gestión de proyectos más eficaz: Implementar una gestión de proyectos que permita una planificación y ejecución más precisas y una asignación de recursos más efectiva, ya que la inexperiencia en el campo hace que se deban realizar más experimentos.
- Optimización de Modelos y algoritmos: Una revisión exhaustiva y optimización de los modelos, podría permitir un entrenamiento más eficiente. Esto incluiría la selección de arquitecturas más eficientes en términos de recursos y ajustes en los hiperparámetros.

Qué recursos estimas que se usarán durante la vida útil del proyecto?Cuál será el impacto ambiental de estos recursos?

Los recursos utilizados durante la vida útil del proyecto incluyen principalmente recursos informáticos, como energía eléctrica y tiempo de procesamiento en servidores. El impacto ambiental de estos recursos se encuentra dentro de los parámetros típicos de proyectos de investigación en informática. Se busca mantener un uso eficiente de estos recursos para reducir al mínimo su impacto.

El proyecto permitirá reducir el uso de otros recursos? ¿Globalmente,

el uso del proyecto mejorará o empeorará la huella ecológica?

El proyecto puede disminuir la necesidad de procedimientos médicos adicionales, contribuyendo a una mejora en la eficiencia de la atención médica y, por lo tanto, tener un impacto positivo en la huella ecológica al reducir la cantidad de recursos utilizados.

Podrían producirse escenarios que hiciesen aumentar la huella ecológica del proyecto?

Podría ocurrir que al aumentar la escala del proyecto o bien debido a un uso ineficiente de recursos informáticos pudiese potencialmente aumentar la huella ecológica.

4.1.3. Impacto económico

Respecto el proyecto puesto en producción (PPP): Reflexión sobre el coste que has estimado para la realización del proyecto.

En el apartado de identificación de los costes se han hecho unas estimaciones bastante detalladas del posible coste de realizar el proyecto. Viendo el coste final, me sorprende ver que el coste final es mayor del que yo inicialmente podría haber imaginado. Esta reflexión es importante para comprender la inversión necesaria y garantizar una planificación financiera adecuada para el proyecto.

Respecto la vida útil, como se resuelve el problema que se quiere abordar (estado del arte) y en que mejorará tu solución, económicamente (costes) respecto a las existentes?

Mi solución tiene el potencial de mejorar económicamente la detección de pólipos, ya que como se ha comentado en el impacto ambiental, al aumentar la precisión pueden reducirse los costes relacionados con diagnósticos erróneos o pruebas adicionales innecesarias. Y también al automatizar partes del proceso de detección es posible que se ahorren costes asociados con el tiempo de los profesionales médicos.

¿Has cuantificado el coste (recursos humanos y materiales) de la realización del proyecto? ¿Qué decisiones has tomado para reducir el coste? ¿Has cuantificado este ahorro?

Se ha cuantificado este coste en el apartado de presupuesto, aparte se ha calculado las horas de entrenamiento de los modelos real, esto a priori era difícil de saber debido a la falta de conocimiento a priori de la complejidad del problema. se calculan unas 288 horas de runtime de los modelos en los ordenadores de la universidad.

Para reducir el coste, se han tomado varias decisiones estratégicas, incluyen-

do:

- **Optimización de modelos:** Se ajustaron los modelos para ser más eficientes en términos de tiempo de entrenamiento. Esto implicó la revisión de las arquitecturas y hiperparámetros para equilibrar entre precisión y eficiencia.
- **Uso de técnicas de aprendizaje por transferencia:** Para reducir el tiempo de entrenamiento, se implementó transferencia de aprendizaje, utilizando modelos preentrenados y ajustándolos a las necesidades específicas del proyecto, lo que redujo significativamente el tiempo de entrenamiento inicial.

En cuanto al ahorro cuantificado, estas medidas permitieron una reducción cuanto menos notable en el tiempo de uso de los recursos computacionales. Aunque el ahorro exacto en términos monetarios puede ser complicado de calcular con precisión, la disminución en el tiempo de entrenamiento y la mejora en la eficiencia de los recursos sin duda contribuyeron a una reducción en el coste general del proyecto.

Se ha ajustado el coste previsto al coste final? ¿Has justificado las diferencias (lecciones aprendidas)?

En general el coste final se ajusta al previsto, con la excepción de que la predicción inicial estimaba 50 horas de entrenamiento para los modelos de aprendizaje profundo, una cifra que se basaba en las expectativas y conocimientos disponibles en las etapas tempranas del proyecto.

- **Aumento significativo en el tiempo de entrenamiento:** en la práctica, el proyecto requirió significativamente más tiempo, alcanzando unas 288 horas de runtime. Este aumento se debió a varios factores inesperados, incluyendo la complejidad de los modelos, la necesidad de ajustes y optimizaciones adicionales, y la profundidad del análisis requerido para garantizar resultados precisos.
- **Subestimación de la complejidad del proyecto:** La estimación inicial de 50 horas no tuvo en cuenta plenamente la complejidad inherente a la visión por computadora en el contexto médico y las particularidades de trabajar con imágenes de colonoscopias. Esto subraya la dificultad de prever con precisión el tiempo necesario para el entrenamiento de modelos en campos especializados y con desafíos técnicos específicos.
- **Lecciones aprendidas:**
 - **Importancia de estimaciones realistas:** Se ha aprendido la importancia de realizar estimaciones más realistas que contemplen posibles complicaciones y desafíos técnicos.

- Planificación financiera flexible: Se ha destacado la necesidad de una planificación financiera flexible y adaptable, capaz de ajustarse a cambios en el desarrollo del proyecto.
- Evaluación continua del progreso: La experiencia subraya la importancia de realizar evaluaciones continuas del progreso del proyecto y ajustar las estimaciones de tiempo y coste en consecuencia.

Qué coste estimas que tendrá el proyecto durante su vida útil? ¿Se podría reducir este coste para hacerlo más viable?

Costes:

- Costes operativos y de mantenimiento: Durante la vida útil del proyecto, habrán costes operativos regulares que incluyen el mantenimiento del hardware y software, así como los costes asociados con el almacenamiento y procesamiento de datos. Estos podrían variar dependiendo de la escala de implementación y del uso del sistema.
- Actualizaciones y ajustes: Con el avance de la tecnología y la evolución de las necesidades de los usuarios, será imprescindible realizar actualizaciones y ajustes en el software. Esto podría incluir la integración de nuevos algoritmos de aprendizaje automático, crear una interfaz de usuario, y adaptaciones a nuevas regulaciones o estándares médicos

Estrategias para reducir costes

Para hacer el proyecto más viable a largo plazo, se pueden adoptar diversas estrategias de reducción de costes, algunas de las cuales ya se han aplicado al proyecto.

- Automatización y eficiencia en procesos: Mejorar la automatización de ciertas tareas y procesos puede reducir la necesidad de intervención manual, lo que a su vez puede disminuir los costes operativos.
- Uso de tecnologías de código abierto: Emplear soluciones de código abierto para ciertos componentes del software puede reducir significativamente los costes de licencias y desarrollo
- Planificación de actualizaciones y mantenimiento: Adoptar un enfoque proactivo en la planificación de actualizaciones y mantenimiento puede ayudar a evitar costes imprevistos y asegurar que el sistema se mantenga al día de manera rentable.

Al estimar el coste total del proyecto, se ha considerado el gasto relacionado con ajustes, actualizaciones y reparaciones

Se ha tenido en cuenta el coste de los ajustes/actualizaciones/reparaciones durante la vida útil del proyecto?

Si, al estimar el coste total del proyecto, se ha considerado el gasto relacionado con ajustes, actualizaciones y reparaciones como se ha explicado anteriormente.

Podrían producirse escenarios que perjudicasen la viabilidad del proyecto?

En el desarrollo y mantenimiento de cualquier proyecto tecnológico, especialmente en el campo de la inteligencia artificial, existen varios escenarios que podrían amenazar su viabilidad. Algunos de estos incluyen:

- Avances tecnológicos rápidos: El campo de la inteligencia artificial y la visión por computadora está en constante evolución. La aparición de nuevas tecnologías o técnicas más avanzadas podría hacer que el sistema actual se vuelva obsoleto.
- Cambios en la regulación y cumplimiento: Las leyes y regulaciones en torno a la privacidad de datos, especialmente en el ámbito de la salud, están sujetas a cambios. Un cambio en las regulaciones podría requerir ajustes costosos en el proyecto.
- Problemas de escalabilidad: Si el proyecto no se diseña teniendo en cuenta la escalabilidad, podría enfrentar dificultades para adaptarse a un mayor volumen de datos o usuarios, lo que afectaría su rendimiento y viabilidad.
- Desafíos en la adopción por usuarios: La resistencia al cambio o la falta de adopción por parte de los profesionales médicos podría limitar la eficacia y el impacto del proyecto. Es por eso que es crucial que el sistema sea intuitivo y que su valor se comunique claramente a los usuarios.

4.1.4. Impacto social

Respecto al proyecto puesto en producción: Qué crees que te aportará a nivel personal la realización de este proyecto?

La realización de este proyecto me aportará crecimiento tanto en lo personal como profesional. A través de la investigación y el desarrollo de soluciones de vanguardia en el campo de la detección, obtendré experiencia en tecnologías de aprendizaje profundo y contribuiré en un área de la medicina con un impacto directo en la salud de las personas. Además, las habilidades de gestión de proyectos adquiridas durante la planificación de este.

Respecto la vida útil: Como se resuelve actualmente el problema que quieres abordar (estado del arte)? En que mejorará socialmente (calidad de vida) tu solución respecto las existentes? Existe una necesidad real del proyecto?

En el estado del arte actual, la detección de pólipos en colonoscopias se basa en gran medida en la experiencia de los médicos y en la inspección visual.

Si bien se han desarrollado sistemas de apoyo a la decisión basados en la visión por computadora, todavía existen desafíos en términos de precisión y eficiencia. [24]

Mi solución tiene el potencial de mejorar la calidad de vida de las personas al permitir una detección más temprana y precisa de pólipos en colonoscopias. Esto podría llevar a diagnósticos más tempranos de cáncer colorrectal, lo que a su vez podría aumentar las tasas de supervivencia y reducir la necesidad de tratamientos invasivos y costosos. También reduciría la carga económica asociada con el tratamiento de cáncer avanzado.

Existe una necesidad real, muy tangible, de proyectos parecidos en el campo de la medicina y la salud. La detección temprana puede aumentar las posibilidades de curación.

¿La realización de este proyecto ha implicado reflexiones significativas a nivel personal, profesional o ético de las personas que han intervenido?

La realización de este proyecto ha implicado reflexiones a nivel personal, profesional y ético. A nivel personal, la investigación y desarrollo de tecnologías médicas avanzadas como esta conlleva una reflexión sobre el impacto positivo que puede tener en la salud de las personas.

A nivel profesional, el proyecto ha requerido un compromiso significativo en términos de conocimiento técnico y habilidades especializadas en aprendizaje profundo y procesamiento de imágenes médicas. Éticamente, se han considerado cuestiones relacionadas con la privacidad de los datos médicos y la seguridad del paciente.

¿Quién se beneficiará del uso del proyecto? ¿Hay algún colectivo que puede verse perjudicado por el proyecto? ¿En qué medida?

El proyecto tiene el potencial de beneficiar a una amplia gama de personas y colectivos. Los beneficiarios principales son los pacientes que se someten a colonoscopias, ya que una detección más precisa y temprana de pólipos puede mejorar significativamente sus perspectivas de salud. Además, los profesionales de la salud se beneficiarán al contar con una herramienta de apoyo a la toma de decisiones más eficaz. Sin embargo, no se prevén efectos perjudiciales significativos para ningún colectivo, ya que el proyecto se centra en mejorar la atención médica y la detección de enfermedades.

¿En qué medida soluciona el proyecto el problema planteado inicialmente?

El proyecto ha abordado de manera efectiva el problema inicialmente planteado, el cual era mejorar la detección de pólipos en imágenes de colonoscopias. A través del uso de tecnologías avanzadas de visión por computadora y aprendizaje profundo, se ha desarrollado un sistema capaz de identificar pólipos. Los resul-

tados de la aumentación de datos no han dado los resultados esperados debido a la naturaleza de CycleGAN, los cambios que debe aplicar a una máscara son demasiado grandes como para que funcione como se espera. Este desafío resalta la importancia de elegir técnicas de aumentación de datos adecuadas para cada tipo específico de imagen médica y su patología.

¿Podrían producirse escenarios que hiciesen que el proyecto fuese perjudicial para algún segmento particular de la población?

No se anticipan escenarios en los que el proyecto sea perjudicial para algún segmento particular de la población. El proyecto se desarrolla con un enfoque en la mejora de la atención médica y la detección temprana de pólipos en colonoscopias, lo que beneficia a un amplio abanico de pacientes y profesionales de la salud.

¿Podría crear el proyecto algún tipo de dependencia que dejase a los usuarios en posición de debilidad?

En este tipo de proyectos, siempre va a existir la posibilidad de producirse tanto falsos positivos como falsos negativos. En consecuencia, el profesional médico en cuestión deberá usar, además de la ayuda que la herramienta pueda proporcionar, su propio criterio. En situaciones negativas, esta herramienta podría condicionar al profesional médico a tomar decisiones incorrectas. Es por esta razón que se debe entender que este tipo de herramientas no son una solución infalible, se deben tratar como lo que son, un apoyo adicional en la toma de decisiones.

4.2. Integración de conocimientos

Durante el desarrollo de este trabajo de fin de grado (TFG), he aplicado una aproximación interdisciplinaria, integrando conocimientos adquiridos en diversos cursos durante mis estudios en Ciencias de la computación en la Facultad de Informática de Barcelona (FIB) de la UPC. Este proyecto refleja disciplinas como el procesamiento de imágenes (Asignatura de Visión por Computador), el aprendizaje automático (APA), el análisis de datos (en l'asignatura de Minería de Datos) u otras como la Probabilidad y estadística. Esto evidencia como la fusión de diversos campos puede conducir a soluciones innovadoras en la detección de objetos en imágenes.

Este TFG se ha beneficiado significativamente de los conocimientos adquiridos en el curso de Visión por Computador. Las técnicas aprendidas en ese curso han sido fundamentales para entender como manipular y preparar las imágenes para su posterior análisis, como demuestra el uso de bibliotecas como PIL y las transformaciones de torchvision.

El curso de Aprendizaje Automático ha proporcionado una base teórica necesaria para entender los modelos de aprendizaje profundo utilizados, como

Faster R-CNN y CycleGAN. La comprensión de estos modelos complejos y su implementación práctica reflejan la integración de conocimientos teóricos y habilidades de programación.

El conocimiento adquirido en l'asignatura de Probabilidad y Estadística ha sido clave también tanto para el análisis e interpretación de los modelos como para comprender conceptos complejos como los "Vanishing Gradients". También ha servido para la comprensión de conceptos como la distribución de los datos, el error estándar y realizar ajustes basados en datos estadísticos.

El trabajo con grandes conjuntos de datos y el análisis de resultados son aspectos clave en este proyecto, donde se aplican técnicas de análisis aprendidas en l'asignatura de Minería de Datos. El uso de K-means para la agrupación de bounding boxes y la evaluación de los resultados con métricas como IoU son ejemplos de esta integración.

La asignatura d'Estructura de Datos y Algoritmos también ha sido importante en el desarrollo del proyecto para poder entender y analizar algoritmos usados en el proyecto, especialmente en la eficiencia del procesamiento de los datos de imagen. La capacidad de estructurar los datos de forma que puedan ser procesadas de forma eficaz es importante, sobre todo cuando tratamos con grandes conjuntos de datos de imágenes.

En resumen, este TFG no solo representa una aplicación práctica de modelos de aprendizaje automático avanzados en el campo de la detección de objetos en imágenes, sino también una fusión efectiva de varias disciplinas estudiadas durante mi grado. A través de esta integración interdisciplinaria, he sido capaz de proponer soluciones que abordan retos en la detección de objetos en imágenes, demostrando así la profundidad y amplitud de los conocimientos adquiridos al largo de mis estudios en ciencias de la computación.

4.3. Identificación de leyes y regulaciones

En la era digital actual, la gestión y protección de datos personales, especialmente en el ámbito de la salud, se ha convertido en un tema de crucial importancia. En este contexto, el proyecto que abordamos implica el procesamiento de conjuntos de datos de imágenes médicas, lo que plantea desafíos significativos en términos de cumplimiento normativo y ético. La sección que sigue tiene como objetivo identificar y discutir las leyes y regulaciones pertinentes, tanto a nivel de la Unión Europea como de España, que rigen la protección de datos y la privacidad, el consentimiento y la aprobación ética, así como otros aspectos relevantes de la gestión de datos médicos. Esta reflexión es esencial para asegurar la integridad, seguridad y legalidad en el manejo de esos datos sensibles y para garantizar que el proyecto se desarrolle, respetando los derechos de los individuos y las normativas vigentes.

- **Protección de datos y privacidad:** Uno de los principales ámbitos de regulación en mi proyecto es la privacidad y la protección de datos. Esto es especialmente relevante dado que el proyecto implica el procesamiento de

conjuntos de datos de imágenes que podrían incluir imágenes de personas. En este contexto he investigado si el proyecto cumplía con el Reglamento General de Protección de Datos (RGPD) de la Unión Europea [25]. Esto incluye asegurar que los datos utilizados para el entrenamiento y la validación de los modelos son anonimizados y no contienen información personal identificable. Esto es algo que se ha llevado a cabo por los investigadores y se especifica en, [13]; sin embargo, hay otros aspectos que no queda muy claro si han seguido las leyes y regulaciones apropiadas.

- **Consentimiento y Aprobación Ética:** Bajo el RGPD, el consentimiento es una de las bases legales para el procesamiento de datos personales, incluyendo datos de categoría especial como la información de salud.

El dataset no proporciona información sobre el consentimiento de los participantes ni sobre la aprobación ética. Esta falta de especificación es una laguna importante en términos de cumplimiento normativo y ético, como se destaca en el estudio [17].

- **Detalles de Recolección de Datos:** El período y el método (retrospectivo o prospectivo) de recolección de datos no se especifican. Aunque el número de centros participantes se menciona, no se detalla el número ni las cualificaciones de los endoscopistas involucrados, ni se definen criterios de elegibilidad como tipo de pólipos o pacientes.

- **Anonimización y Anotación de Datos:** La RGPD define los «datos personales» como cualquier información relacionada con una persona natural identificada o identificable. Si un paciente no es identificable porque el conjunto de datos de entrenamiento ha sido anonimizado, el desarrollador del algoritmo de ML puede procesar la información sin consentimiento ni ninguna otra base legal. Esto evita las dificultades de cumplimiento del RGPD. [12].

Se aplican métodos de anonimización de datos y se describe detalladamente el uso de herramientas de anotación asistida por seguimiento para la eficiencia en la anotación de datos por expertos.

- **Variables y Demografía:** No se incluye información sobre la variabilidad inter/intra observador, ni demografía de los pacientes o de los pólipos (como la distribución del tipo de histología, tamaño y morfología). Sin embargo, se proporciona el número de casos únicos, cantidad de fotogramas, modalidad de imagen, y se especifica la resolución y el tipo de archivo utilizado.
- **Equipamiento y Tecnología Utilizada:** No se menciona la marca del sistema de endoscopia utilizado en el estudio.

Capítulo 5

Red de Segmentación

5.1. Modelos elegidos

Para asegurar-nos de utilizar un buen modelo de detección de objetos, experimentaremos con los siguientes modelos explicados a continuación.

5.1.1. FastRcnn / FasterRCNN

Fast R-CNN es un algoritmo de detección de objetos que fue una evolución importante respecto a R-CNN (Region-based Convolutional Neural Network). Fast R-CNN mejora la eficiencia al compartir cálculos y utilizando una red neuronal convolucional (CNN) para procesar la imagen completa de una sola pasada. En [26], se describe con detalle la estructura de este modelo. Su funcionamiento es el siguiente:

Fast R-CNN toma como entrada una imagen completa y un conjunto de propuestas de regiones de objetos, que son rectángulos que podrían contener objetos. Estas propuestas de regiones a menudo se generan mediante un algoritmo como Selective Search.

La imagen completa se pasa a través de una CNN, que genera un mapa de características convolucionales de la imagen.

Para cada propuesta de región (Region of Interest o ROI), se extrae la parte correspondiente del mapa de características convolucionales. Esta extracción se realiza utilizando una operación llamada ROI Pooling, que redimensiona la porción extraída a un tamaño fijo para que pueda ser procesada de manera uniforme. Esto es importante porque las propuestas de regiones pueden tener diferentes tamaños, pero la red necesita un tamaño de entrada fijo para la clasificación.

Las características fijas obtenidas después del ROI Pooling se pasan por una serie de capas totalmente conectadas. Estas capas tienen dos salidas:

- Clasificación: para cada ROI, la red produce una distribución de probabilidad sobre las clases de objetos, incluida una clase de fondo que significa

«ningún objeto».

- Regresión de Bounding Box: Para cada ROI, la red también produce cuatro valores que son ajustes a las coordenadas de la propuesta de región. Estos ajustes se hacen para mejorar la precisión de la ubicación y el tamaño del cuadro delimitador predicho




Figura 5.1: FastRCNN

Fuente [26]

Faster R-CNN

En nuestro caso se usará Faster R-CNN, una evolución de Fast R-CNN que mejora la eficiencia en la detección de objetos al integrar la generación de propuestas de región en la red neuronal. En [3] encontramos la explicación en detalle, pero las ideas principales son las siguientes:

Se introduce una RPN que escanea el mapa de características de la imagen y propone regiones candidatas donde podría haber objetos. La RPN utiliza los llamados «anclajes» en cada ubicación del mapa de características para generar propuestas. Los anclajes son unas cajas delimitadoras de referencia para detectar objetos. Cada anclaje está centrado en un punto diferente de la imagen y está predefinido para cubrir varias escalas y relaciones de aspecto. Estos anclajes sirven como puntos de partida para la RPN, que ajusta sus dimensiones para proponer regiones que puedan contener objetos. La idea es que independientemente del tamaño y la forma reales de los objetos en la imagen, al menos algunos de los anclajes coincidan suficientemente bien como para que la RPN los identifique y ajuste para crear propuestas de regiones precisas.

Las propuestas generadas por la RPN se pasan por una capa de ROI Pooling, al igual que en Fast R-CNN, para convertirlas en un tamaño fijo que pueda ser procesado por la red.

Utilizando las características resultantes del ROI Pooling, la red realiza dos tareas: clasificar la región propuesta en una categoría de objeto y refinar la

ubicación y el tamaño del cuadro delimitador a través de la regresión del cuadro delimitador.

La RPN y encabezados de clasificación y regresión de cuadros delimitadores se entrenan de forma conjunta con un entrenamiento de extremo a extremo. El modelo se suele entrenar de forma alterna entre mejorar las regiones propuestas y la detección de objetos.

Al integrar la generación de propuestas en la red, se consigue reducir la cantidad de propuestas en un orden de magnitud. También, al descubrir que se podían usar los mismos mapas de características tanto en la RPN y en la detección de objetos, consigue hacer uso de los recursos computacionales de forma mucho más eficiente.




Figura 5.2: FasterRCNN

Fuente [3]




Figura 5.3: Region Proposal Network

Fuente [3]

5.1.2. SSD

SSD o Detector Multibox de disparo único, es una técnica de detección de objetos en imágenes. Esta metodología destaca por su capacidad de realizar la detección de objetos en una sola pasada por la red, a diferencia de otras técnicas como la que hemos visto antes, FastRCNN que requieren de múltiples etapas.

La arquitectura de SSD, combina una red neuronal convolucional base como por ejemplo VGG16 para la extracción de características (features), con capas convolucionales adicionales que se encargan de detectar objetos en diferentes escalas. Esta característica es importante para detectar objetos de diferentes tamaños, aprovechándose de los mapas de características a diferentes niveles de la red, de forma intuitiva los niveles superiores sirven para objetos pequeños y los niveles profundos para los objetos grandes.

Las innovaciones clave en SSD incluyen:

- Pequeños filtros convolucionales para la predicción de objetos y ajustes en las ubicaciones de las cajas delimitadoras: Estos filtros permiten que SSD realice predicciones de manera más eficiente y con menos parámetros en comparación con las capas densas utilizadas en otros modelos.
- Predictores separados para diferentes proporciones de aspecto de las cajas delimitadoras: SSD utiliza conjuntos específicos de filtros para manejar variadas formas y tamaños de objetos, mejorando la precisión en la detección de objetos con diferentes proporciones.
- Aplicación de filtros en múltiples mapas de características para detección en varias escalas: A diferencia de modelos que usan un solo mapa de ca-

racterísticas, SSD aplica sus filtros a través de varios mapas, lo que lo permite detectar objetos de diferentes tamaños de manera más efectiva.

El método MultiBox sirve para predecir las ubicaciones de los objetos mediante cajas delimitadoras. Durante el entrenamiento, SSD utiliza un conjunto de cajas delimitadoras predeterminadas (parecidas a los anchors del RPN que hemos visto en FasterRCNN). Estas cajas son de varios tamaños y proporciones, el modelo aprende a ajustar estas cajas para coincidir con las reales en los datos de entrenamiento, así como a determinar la probabilidad de la clase del objeto.

Una de las ventajas de SSD es su velocidad, ya que al ser de disparo único, es decir, solo se procesa una vez por la red, es más rápido.

Los detalles de la implementación los encontramos en [2]




Figura 5.4: Comparación entre dos diagramas de disparo único, SSD y YOLO

Fuente [2]

5.1.3. RetinaNet / Detectron

RetinaNet es una arquitectura de deep learning diseñada para la detección de objetos. Se introdujo por la Facebook AI Research y se conoce por ser efectiva a la hora de detectar objetos a través de un gran rango de escalas y bajo condiciones variadas. En [5], podemos encontrar los detalles de la implementación. A continuación explicaremos el modelo:

El componente clave de esta red es su función de pérdida Focal. Esta está diseñada para abordar el problema del desequilibrio de clases, común en la detección de objetos donde la mayoría de las cajas ancla son fondo y solo unas pocas son realmente objetos.

La pérdida Focal escala dinámicamente la contribución de la pérdida de cada caja ancla basándose en qué tan bien el modelo predice su clase. Si una ancla se clasifica correctamente con alta confianza, su pérdida se reduce. Esto ayuda al modelo a enfocarse más en ejemplos difíciles y mal clasificados.

RetinaNet también hace uso de la red piramidal de características (FPN), la utiliza para detectar objetos eficientemente en múltiples escalas. La FPN se construye sobre una CNN base como por ejemplo ResNet. Crea una pirámide de mapas de características en múltiples escalas, permitiendo que la red detecte objetos de varios tamaños. La pirámide involucra conexiones tanto descendentes como laterales, lo que permite a la red combinar características de baja resolución, semánticamente fuertes, con características de alta resolución, semánticamente débiles.

Similar a otros detectores como SSD, RetinaNet utiliza cajas ancla de diferentes tamaños y proporciones para detectar objetos. Aplica estas anclas a cada nivel de la pirámide de características, permitiéndole capturar objetos de diferentes tamaños.

Funcionamiento del modelo

Una imagen se introduce en la red, que pasa primero por una CNN base (como ResNet) para extraer los mapas de características. Estos mapas de características se procesan a través de la FPN para crear una rica pirámide de características multi-escala. Luego pasa a través de una sub-red de detección. La red tiene dos subredes: una para clasificar objetos dentro de las cajas ancla y otra para ajustar las cajas delimitadoras (regresión). La sub-red de clasificación predice la probabilidad de que un objeto esté presente en cada caja ancla, mientras que la sub-red de regresión refina las coordenadas de las cajas ancla.

Durante el entrenamiento, se aplica la función de Pérdida Focal para guiar al modelo a concentrarse en ejemplos difíciles.




Figura 5.5: Diagrama de la arquitectura de RetinaNet

Fuente [5]

Ventajas

Es efectiva en objetos pequeños gracias a la FPN. RetinaNet es considerablemente efectiva en detectar objetos pequeños, algo que es un desafío para muchas tareas de la detección de objetos. Equilibrio del desequilibrio de clases: La función de Pérdida Focal ayuda a equilibrar el proceso de aprendizaje, previniendo que un número abrumador de negativos fáciles domine el entrenamiento de la red. Alto rendimiento: se ha demostrado que RetinaNet logra alta precisión y eficiencia, haciéndolo adecuado para varias aplicaciones, desde monitoreo de tráfico hasta vigilancia en tiempo real.

5.2. Métricas de evaluación

En este apartado se van a introducir las métricas que se han considerado adecuadas para determinar el rendimiento de los modelos

- **Precisión:** Es la proporción de verdaderos positivos (TP) frente a todos los casos clasificados como positivos. Es una forma de medir como de exactas son las predicciones positivas del modelo. $Precision = \frac{TP}{TP+FN}$ FN es el número de falsos negativos.
- **Recall:** se conoce también como Sensibilidad, es la proporción de verdaderos positivos entre los que son realmente positivos. $Recall = \frac{TP}{TP+FN}$
- **F1 score:** Esta medida tiene en cuenta tanto la precisión como el recall e intenta equilibrar ambas métricas, lo hace a través de la media armónica de la precisión y el recall. Es una métrica útil cuando la distribución de clases es desigual. $F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$
- **Average Precision (AP):** esta métrica resume la curva de precisión-recall, que es una gráfica que muestra la precisión del modelo en función del recall para diferentes thresholds. $AP = \sum_n (R_n - R_{n-1}) P_n$ Donde P_n y R_n son la precisión y el recall con umbral n.
- **Intersection over Union (IoU):** Esta métrica se utiliza para medir la solapación entre las cajas englobantes predichas y las reales.

5.3. Optimización de hiperparámetros

En el aprendizaje automático, los hiperparámetros son parámetros cuyos valores se establecen antes de iniciar el proceso de entrenamiento. A diferencia de los parámetros del modelo, que se aprenden durante el entrenamiento, los hiperparámetros se utilizan para controlar el proceso de aprendizaje y pueden tener un impacto significativo en el rendimiento del modelo.

5.3.1. ¿Qué es Optuna?

Optuna es un framework de optimización de hiperparámetros diseñado para ser ligero y versátil. Permite automatizar la búsqueda de los mejores hiperparámetros para tu modelo. Optuna es especialmente potente debido a su capacidad para realizar una búsqueda eficiente utilizando métodos basados en el historial de pruebas anteriores.

Se debe definir una función objetivo, en nuestro caso es `objective(trial)`: esta función es el núcleo de la optimización y se invoca en cada prueba (`trial`) de Optuna. Dentro de esta función, se definen los hiperparámetros a optimizar, como la tasa de aprendizaje (`'lr'`), tamaño del lote (`'batch size'`) y el decay del peso (`'weight decay'`). La función regresa una métrica de rendimiento (como el F1 score o mean IOU) que Optuna intentará maximizar o minimizar.

Optuna utiliza algoritmos inteligentes para seleccionar la próxima combinación de hiperparámetros basándose en los resultados anteriores.

Después de completar todas las pruebas, Optuna proporciona la mejor configuración de hiperparámetros encontrada. Estos hiperparámetros son los usados en la configuración final.

La optimización de hiperparámetros juega un papel crucial en el desarrollo de modelos de aprendizaje automático eficientes. La elección correcta de hiperparámetros puede significar la diferencia entre un modelo mediocre y uno altamente preciso.

Se llevó a cabo un estudio con Optuna limitado a 5 pruebas. El objetivo era explorar un espacio de hiperparámetros definido y encontrar la configuración óptima dentro de este espacio limitado.

En el script que utiliza Optuna, la definición del espacio de hiperparámetros es un paso fundamental. Aquí es donde se especifican los rangos y los tipos de hiperparámetros que Optuna explorará durante el proceso de optimización. Veamos cómo se define cada hiperparámetro:

- **Tasa de aprendizaje:** Se define la tasa de aprendizaje como un valor flotante en una escala logarítmica entre $1e-5$ y $1e-1$. La escala logarítmica es útil cuando no estamos seguros del orden de magnitud que la tasa de aprendizaje debe tener.
- **Tamaño del lote:** Aquí, el tamaño del lote se selecciona de un conjunto de valores categóricos. En este caso, los posibles tamaños del lote son 2, 4 y 8. Se nota que un tamaño de 16 puede y seguramente causará problemas, esto es debido a una limitación encontrada durante la fase de pruebas. Esto es debido a que la memoria de la tarjeta gráfica no es suficientemente grande como para soportar las cargas de un tamaño de lote 16, la tarjeta gráfica utilizada ronda los 12 GB de memoria.
- **Decay de peso:** Similar a la tasa de aprendizaje, el decay de peso se busca en una escala logarítmica, lo que permite explorar un amplio rango de valores.

- **Número de épocas:** Este hiperparámetro se define como un entero entre 1 y 5. Se añade como comentario la posibilidad de aumentar el número de épocas en el futuro cuando haya más tiempo disponible para experimentar, esto es igualmente cierto para el número de pruebas o 'trials'.

Los resultados fueron los siguientes:

- **Número de pruebas:** 5
- **Mejores hiperparámetros encontrados:**
 - **Tasa de Aprendizaje** (lr): 0.030835981129087326
 - **Tamaño del Lote** (batch size): 2
 - **Decay de Peso** (weight decay): 0.0001317937713104395
 - **Número de Épocas** (num epochs): 2

Discusión de los resultados:

- **Tasa de Aprendizaje:** Un valor relativamente mayor, lo que sugiere que el modelo se beneficia de pasos de aprendizaje más grandes en el espacio de parámetros
- **Tamaño del lote:** Un tamaño pequeño, lo que podría indicar que el modelo responde mejor a actualizaciones de parámetros más frecuentes.
- **Decay de peso:** Un valor muy bajo, lo que sugiere que una regularización menos estricta es preferible para este conjunto de datos.
- **Número de épocas:** Se prefieren menos épocas, lo que puede ser indicación de que el modelo aprende las características esenciales del conjunto de datos rápidamente

5.3.2. RayTune

Después de discutir Optuna, que ofrece un enfoque eficiente y flexible para la optimización de hiperparámetros, resulta relevante explorar cómo otras herramientas pueden complementar o mejorar este proceso. Aquí es donde entra en juego Ray Tune, una biblioteca que no solo se centra en la optimización de hiperparámetros, sino también en la escalabilidad y la distribución del proceso de entrenamiento.

Ray Tune se distingue por su capacidad para escalar y distribuir la optimización de hiperparámetros en múltiples núcleos o incluso en clústeres. Este enfoque es particularmente beneficioso cuando se trabaja con grandes conjuntos de datos o modelos complejos que requieren una cantidad sustancial de recursos computacionales.

Razones para utilizar Ray Tune:

- **Escalabilidad:** Ray Tune brinda la capacidad de escalar el proceso de la búsqueda eficiente de hiperparámetros a través de múltiples GPUs o incluso en clústeres, lo que es crucial para experimentos a gran escala.
- **Distribución del proceso de entrenamiento:** Ray Tune permite distribuir el proceso de entrenamiento de los modelos, lo cual es una ventaja significativa cuando se manejan arquitecturas de modelos grandes.
- **Integración con diferentes frameworks y herramientas:** Ray tune se integra de manera efectiva con una variedad de frameworks de aprendizaje automático y librerías de optimización, incluyendo la propia Optuna, lo que permite una mayor flexibilidad y robustez en el proceso de optimización.
- **Evaluación comparativa:** Utilizar tanto Optuna como Ray Tune proporciona una base sólida para la evaluación comparativa. Se puede comparar los resultados obtenidos con cada herramienta.
- **Funcionalidades avanzadas:** Ray Tune ofrece funcionalidades avanzadas como la detención temprana (early stopping y los schedulers inteligentes (como ASHAScheduler) que pueden mejorar la eficiencia de la optimización

Para los propósitos de este TFG se ha implementado una versión similar del código de Optuna, pero utilizando el framework de Ray Tune, desafortunadamente no se ha podido probar en múltiples GPUs, ya que no he recibido la cuenta del BSC para entrenar los modelos.

5.4. Automatización

La automatización en el aprendizaje automático desempeña un papel fundamental en la mejora de la eficiencia y la consistencia de los procesos de entrenamiento y evaluación de modelos. Permite al investigador y científico de datos centrarse en aspectos más analíticos del proyecto, mientras que las tareas repetitivas y susceptibles a errores humanos se manejan de manera sistemática.

5.4.1. Proceso automatizado de evaluación de modelos

En el proyecto se ha implementado un proceso de automatización para evaluar una serie de modelos de aprendizaje automático. Este proceso incluye la ejecución de scripts de evaluación para cada modelo entrenado, el cálculo de métricas de rendimiento y la consolidación de estos resultados en un archivo CSV. Esta metodología asegura que cada modelo se evalúe bajo los mismos criterios y en un entorno controlado, garantizando así la fiabilidad de los resultados.

Pasos:

- **Preparación de Datos y Modelos:**

- Los modelos entrenados se almacenan en un directorio específico, listos para ser evaluados.
 - Los conjuntos de datos de prueba se preparan de antemano para garantizar la consistencia en todas las evaluaciones.
- **Ejecución Automatizada de Evaluaciones:**
 - Un script recorre todos los archivos de modelo en el directorio especificado.
 - Para cada modelo, se calculan métricas de rendimiento utilizando el conjunto de datos de prueba.
 - **Recopilación y Registro de resultados:**
 - Las métricas de rendimiento se recopilan y registran sistemáticamente para cada modelo.
 - Los resultados se adjuntan en un archivo CSV, proporcionando un registro estructurado y fácil de analizar.
 - **Generación de Archivos:**
 - El archivo CSV incluye detalles como el nombre del modelo, las métricas de rendimiento y posiblemente hiperparámetros utilizados.
 - Este archivo sirve como un resumen integral del rendimiento de todos los modelos evaluados.
 - El archivo se va actualizando con cada evaluación de un modelo, para evitar perder todos los datos en caso de interrupción.

5.5. Prueba y Visualización de modelos

La prueba y visualización de modelos son etapas importantes, ya que permiten verificar el rendimiento del modelo en datos no vistos y además ofrecen una comprensión intuitiva de cómo el modelo interpreta y procesa los datos. Este proceso es esencial para asegurar que el modelo funcione según lo esperado antes de su despliegue o uso práctico.

El script 'test model' realiza una serie de pasos para probar y visualizar el rendimiento de un modelo entrenado previamente.

- **Carga del modelo:** El modelo previamente entrenado se carga desde un archivo, asegurando que se utilicen los pesos y la configuración exacta que se entrenaron
- **Preparación del conjunto de datos:** se prepara el conjunto de datos de prueba que consta de datos no utilizados durante el entrenamiento, para evaluar cómo el modelo generaliza a nuevos ejemplos.
- **Ejecución del Modelo y recolección de Resultados:**

- El modelo se ejecuta en el conjunto de datos de prueba.
- Se recolectan las predicciones del modelo.

■ **Visualización de resultados:**

- Se utilizan herramientas de visualización para mostrar cómo el modelo ha interpretado los datos de prueba.
- Se visualizan las imágenes de las cajas delimitadoras predichas con sus etiquetas de clasificación y también se muestran las cajas delimitadoras reales, así podemos inspeccionar visualmente si el modelo está funcionando correctamente.

Esta evaluación es esencial para asegurar la fiabilidad y la eficacia del modelo en aplicaciones del mundo real. Además, proporciona insights valiosos sobre cómo el modelo podría ser mejorado.

5.6. Preparación del dataset

5.6.1. Carga del dataset

Un conjunto de datos personalizado en aprendizaje automático es una colección de datos que ha sido preparada específicamente para un caso de uso particular. En muchos casos, los datos disponibles no se ajustan directamente a los formatos requeridos por las bibliotecas de aprendizaje automático estándar, por lo que es necesario desarrollar un script personalizado que pueda procesar y presentar estos datos de una forma utilizable para el modelo.

Los componentes del script para cargar los datos del dataset son los siguientes:

- **Clase CustomDataset:** esta clase hereda de Dataset en pytorch. En esta clase se define como se cargan, almacenan y acceden a los datos.
- **Inicialización y preparación de datos:** En el método init se define la estructura del conjunto de datos, incluyendo las rutas a las imágenes, las anotaciones y cualquier transformación de datos que deba aplicarse a las imágenes.
- **Método len:** Este método devuelve el número total de elementos en el conjunto de datos
- **Método get item:**
 - Este método es crucial, ya que define cómo se accede a cada elemento del conjunto de datos.
 - Carga cada imagen y sus anotaciones correspondientes. Si se han definido transformaciones se aplican aquí

- Las anotaciones, que pueden incluir cajas delimitadoras para las tareas de detección de objetos, también se procesan en este método.
- **Función de anotación:** Una función auxiliar `parse_annotation` que se utiliza para leer archivos de anotación de un archivo `txt` y extraer la información relevante sobre las cajas delimitadoras de los pólipos.
- **Colección de Rutas de imágenes y Anotaciones:** Se implementa una lógica para recopilar las rutas a las imágenes y sus anotaciones correspondientes, asegurando que cada imagen se empareje correctamente con su anotación.

Esta implementación muestra como se pueden manejar datos que no se ajustan a los formatos estándar.

5.7. Entrenamiento de los modelos

En el contexto de la detección de objetos en imágenes, el entrenamiento de modelos es un paso fundamental para lograr una alta precisión y eficacia. El script `model_utils.py` encapsula la lógica necesaria para el entrenamiento de modelos de aprendizaje profundo, específicamente para la tarea de detección de objetos. Este módulo es crucial, ya que define y gestiona los aspectos más significativos del proceso de entrenamiento, incluyendo la preparación de datos, configuración del modelo y la optimización de los parámetros.

5.7.1. Configuración del modelo

El script proporciona una función `get_model` para configurar el modelo deseado. Esta función es versátil y puede adaptarse para configurar diferentes arquitecturas de modelos como Faster R-CNN, SSD y RetinaNet. Dependiendo del modelo seleccionado, la función ajusta automáticamente la arquitectura, por ejemplo, cambiando el número de clases en el clasificador final del modelo.

- **Propósito y Funcionalidad General:** `get_model` sirve como una fábrica de modelos, donde se configuran y se devuelven instancias de diferentes modelos de detección de objetos según los requisitos del usuario. La función está diseñada para manejar múltiples arquitecturas como Faster R-CNN, SSD y RetinaNet. Esto permite seleccionar y experimentar con diferentes modelos sin la necesidad de escribir código específico para cada uno.
- **Parámetros y configuración:** La función acepta principalmente dos parámetros `model_name` y `num_classes`. El `model_name` determina la arquitectura del modelo a utilizar, mientras que `num_classes` especifica el número de clases que el modelo debe predecir, incluyendo la clase de fondo.
- **Implementación para diferentes arquitecturas:**

- **Faster R-CNN:** Cuando se selecciona Faster R-CNN, la función carga un modelo preentrenado utilizando pesos estándar y luego modifica la cabeza del clasificador para adaptarlo al número específico de clases del conjunto de datos. Esto se hace cambiando el número de características de entrada y salida en el predictor de cajas del modelo.
- **SSD (Single Shot MultiBox Detector):** En el caso de SSD, se realiza un proceso similar. La función ajusta la arquitectura para manejar el número deseado de clases. Se hace especial énfasis en ajustar la cabeza de clasificación del modelo.
- **RetinaNet:** Para RetinaNet, se sigue un enfoque similar al de Faster R-CNN y SSD, adaptando la red para el conteo de clases deseado. Aquí también se manejan configuraciones específicas relacionadas con los anclajes y la capa de clasificación.
- **Flexibilidad y adaptabilidad:** La mayor ventaja de la función `get model` radica en su capacidad para adaptarse a diferentes necesidades y escenarios. Al proporcionar un punto de acceso unificado para varias arquitecturas de modelos, simplifica el proceso de experimentación con diferentes modelos. Esto es particularmente valioso en la investigación y el desarrollo de aplicaciones de detección de objetos, donde la selección del modelo adecuado es crucial para el rendimiento general.

5.7.2. Entrenamiento

El proceso de entrenamiento se maneja mediante la función `train model`. Esta función toma el conjunto de datos de entrenamiento, los parámetros de entrenamiento (como la tasa de aprendizaje, tamaño del lote y peso de la regularización), y ejecuta un bucle de entrenamiento para el número especificado de épocas. Dentro de este bucle, se realiza la propagación hacia adelante y la retropropagación para actualizar los pesos del modelo. Además, se implementa un esquema de validación para evaluar el rendimiento del modelo en un conjunto de datos de validación separado. Este paso es crucial para evitar el sobreajuste y garantizar que el modelo generalice bien a nuevos datos.

A continuación se analiza en detalle cada componente de esta función.

- **Estructura y parámetros:** La función `train model` toma varios argumentos importantes
 - **train dataset:** Conjunto de datos de entrenamiento
 - **param:** Diccionario que contiene hiperparámetros como tasa de aprendizaje tamaño del lote, y peso de la regularización.
 - **num epochs:** Número de épocas para entrenar el modelo
 - **device:** Dispositivo de cálculo (CPU o GPU)
 - **model:** indicador del modelo a entrenar, por ejemplo 'FasterRCNN'

- **debug:** Modo de depuración para controlar aspectos como la verbosidad
- **División del conjunto de datos y preparación del DataLoader:** La función comienza dividiendo el conjunto de datos de entrenamiento en subconjuntos de entrenamiento y validación. Luego, crea un 'DataLoader' para ambos conjuntos, lo que facilita la iteración eficiente y la carga de lotes de datos durante el entrenamiento y la validación.
- **Configuración del Modelo y Optimizador:** train model configura el modelo llamando a get model, pasando el nombre del modelo y el número de clases. Luego, inicializa el optimizador (SGD, Stochastic Gradient Descent) con los parámetros del modelo y los hiperparámetros definidos.
- **Bucle de Entrenamiento:** El entrenamiento se realiza a través de un bucle que itera por el número especificado de épocas. Cada época consiste en:
 - **Entrenamiento:** Para cada lote en el train loader, realiza la propagación hacia adelante y la retropropagación. Esto implica calcular las pérdidas y actualizar los pesos del modelo.
 - **Validación:** Después de cada época, evalúa el rendimiento del modelo en el conjunto de validación. Esto ayuda a monitorear la generalización del modelo y ajustar si es necesario (por ejemplo, para evitar el sobreajuste).
- **Evaluación y Guardado del modelo:** Durante el entrenamiento, train model también evalúa el modelo utilizando la métrica especificada. Si el modelo alcanza un rendimiento óptimo en esta métrica, se guarda el estado del modelo actual. Esto asegura que se preserve la mejor versión del modelo durante el proceso de entrenamiento.
- **Ajuste de la Tasa de aprendizaje:** el script emplea un programador de tasa de aprendizaje lr scheduler para ajustar dinámicamente la tasa de aprendizaje durante el entrenamiento. Esto puede mejorar la convergencia del modelo y prevenir problemas como el estancamiento en mínimos locales.
- **Manejo de debug:** El modo de depuración, si se activa, puede proporcionar salidas verbosas que incluyen información detallada sobre el proceso de entrenamiento. Esto es útil para el diagnóstico y la optimización del proceso de entrenamiento.

5.7.3. Validación

La función 'coco evaluate' se utiliza para evaluar las predicciones de un modelo de aprendizaje profundo utilizando el formato y métricas de COCO

(Common Objects In Context), un estándar en la evaluación de modelos de visión por computadora.

(La iteración previa a esta función utilizaba algoritmos propios que no daban resultados tan buenos como los de esta librería, por lo que se decidió adaptar el dataset para usar la librería en cuestión.)

Funcionamiento:

- La función toma como entrada un 'model' un cargador de datos 'val loader' y un 'device' donde realizar los cálculos.
- Inicialización:
 - Se pone el modelo en modo de evaluación
 - Se preparan estructuras de datos para almacenar la información del conjunto de datos COCO, incluyendo imágenes, anotaciones y categorías
- Se definen las categorías de los objetos a detectar en nuestro caso 'pólipos'.
- Procesamiento de imágenes y generación de predicciones:
 - La función itera sobre cada lote de imágenes dado por 'val loader'
 - Cada imagen se procesa con el modelo para obtener predicciones.
 - Se extrae información relevante de cada imagen como su identificador, dimensiones y nombre de archivo.
- Conversión a COCO: Las predicciones y las 'ground truths' se convierten a formato COCO. Para pasar a este formato hay que incluir identificadores de imagen, coordenadas de las cajas delimitadoras y los 'scores'
- Carga y evaluación:
 - Se carga la información de las predicciones y de las ground truth en objetos COCO. También se inicializa un objeto COCOeval para evaluar, y se especifica que se evaluarán cuadros delimitadores 'bbox' (hay opción de evaluar segmentaciones)
 - La función ejecuta el proceso de evaluación que calcula, entre otras cosas métricas como la Precisión y el Recall a diferentes umbrales de IoU (intersection over Union).
- Finalmente, CocoEval acumula y devuelve los resultados de la evaluación.

5.7.4. Manejo personalizado de batches

En tareas de detección de objetos, cada muestra de entrenamiento consiste generalmente en una imagen y sus correspondientes anotaciones (las bounding boxes). Sin embargo, cada imagen puede tener un número variable de objetos,

lo que implica que el tamaño de las anotaciones puede variar significativamente entre las muestras. Esto representa un desafío al formar lotes (batches) de muestras para el entrenamiento, ya que los lotes deben tener dimensiones consistentes.

La función `collate_fn` en PyTorch es una herramienta esencial para abordar este desafío. Su propósito es definir cómo se deben agrupar múltiples muestras para formar un lote, permitiendo un manejo eficiente de datos con dimensiones variables.

- **Entrada:** La función recibe como entrada 'batch', que es una lista de tuplas, donde cada tupla contiene una imagen y sus correspondientes (targets)
- **Desempaquetado de datos:** utiliza la función `zip(*batch)` para desempaquetar el lote. Esto separa las imágenes y los targets en dos listas distintas.
- **Procesamiento de Imágenes:** Las imágenes se procesan con `torch.stack(images, dim=0)`, que apila las imágenes a lo largo de una nueva dimensión para formar un tensor 4D. Esto es necesario porque las imágenes generalmente tienen la misma dimensión y se pueden apilar juntas de manera efectiva.
- **Procesamiento de Targets:** Los targets no se modifican ni se apilan, ya que los modelos de detección de objetos como Faster R-CNN en PyTorch están diseñados para manejar targets de tamaño variable. Por lo tanto, los targets se devuelven como una lista de diccionarios, donde cada diccionario contiene las anotaciones de una imagen en particular.

Para ilustrar cómo se transforma el valor de `images` antes y después de aplicar `torch.stack(images, dim=0)` consideremos un ejemplo concreto: Supongamos que estamos trabajando con un lote de imágenes en un modelo de detección de objetos, y cada imagen tiene un tamaño de 224 x 224 píxeles y 3 canales de color (RGB)

`[[3,224,224], [3,224,224], [3,224,224], [3,224,224]]` Cada elemento de esta lista representa un tensor que representa una imagen individual. La forma del tensor resultante sería `[4, 3, 224, 224]`. Donde el primer número representa la cantidad de imágenes en el lote, seguido de los canales de color y las dimensiones espaciales.

Este tensor 4D es más conveniente para procesar en un modelo de aprendizaje profundo, ya que los modelos suelen esperar lotes de imágenes como entrada, no imágenes individuales.

5.7.5. Carga y Guardado de los modelos

La gestión eficiente de los modelos entrenados es crucial en proyectos de aprendizaje profundo. Las funciones 'save model with hyperparams' y 'load model with hyperparams' desempeñan un papel fundamental en este proceso, manejando respectivamente el guardado y la carga de los modelos junto con sus hiperparámetros.

Función 'save model with hyperparams'

Esta función se encarga de guardar no solo el estado de un modelo entrenado sino también los hiperparámetros utilizados durante su entrenamiento.

Funcionalidad:

- **Guardado del estado del modelo:** Guarda los pesos del modelo en un archivo, utilizando la función `torch.save`.
- **Incorporación de hiperparámetros:** Junto con el modelo, guarda los hiperparámetros que se utilizaron en su entrenamiento. Esto se logra incorporando estos detalles en el nombre del archivo.
- **Registro de métricas de entrenamiento:** La función también permite guardar métricas adicionales como las pérdidas por época y por lote, lo cual es útil para análisis posteriores.

Función 'load model with hyperparams'

Esta función complementa a 'save model with hyperparams' al facilitar la carga de modelos previamente guardados, asegurando que se recuperen los pesos del modelo como los detalles de los hiperparámetros utilizados.

Funcionalidad:

- **Carga del estado del modelo:** Recupera los pesos del modelo guardados, utilizando la función `torch.load`.
- **Recuperación de hiperparámetros:** La función está diseñada para leer el nombre del archivo del modelo, que contiene los hiperparámetros utilizados, permitiendo una fácil referencia a la configuración con la que fue entrenado el modelo.
- **Flexibilidad en la gestión de modelos:** Facilita la experimentación y comparación entre diferentes modelos y configuraciones, ya que los hiperparámetros asociados con cada modelo se conservan y pueden ser fácilmente referenciados.

El uso conjunto de ambas funciones ofrece un sistema robusto para el manejo de modelos de aprendizaje profundo. Esta metodología asegura que los modelos no se traten como entidades aisladas, sino como parte de un experimento más amplio que incluye su configuración de entrenamiento. Esta práctica es esencial para la reproducibilidad y la interpretación efectiva de los resultados en proyectos de aprendizaje automático.

Capítulo 6

Red de Aumentación de Datos

6.1. Modelos

Para conseguir generar imágenes estadísticamente parecidas a nuestras imágenes reales experimentaremos con los siguientes modelos.

6.1.1. CycleGAN

CycleGAN es un tipo de red generativa adversaria (GAN) diseñada para tareas de transferencia de estilo entre dominios sin necesidad de parejas de datos emparejados. Es decir, puede aprender a transformar imágenes de un dominio a otro sin que las imágenes de entrenamiento estén específicamente alineadas o sean correspondientes entre los dominios. En nuestro caso las usaremos para transformar cuadros delimitadores de los pólipos en imágenes que se parezcan a pólipos reales. Los detalles de implementación los encontramos en [7].

Componentes clave

CycleGAN utiliza dos redes generativas, una para cada dirección de la transformación (por ejemplo de A a B y de B a A). Es decir, en nuestro caso tendremos una red que transformará de cuadro delimitador a pólipo «real» y otra red que transformará de pólipo real a cuadro delimitador.

Para cada dirección de la transformación, hay una red discriminativa correspondiente. El trabajo de cada discriminador es diferenciar entre imágenes reales del dominio objetivo y las imágenes generadas por su generador correspondiente.

Ciclo de consistencia: La característica distintiva de CycleGan es la restricción de consistencia de ciclo. Significa que si una imagen del dominio A se transforma en el dominio B y luego se vuelve a transformar al dominio A, debería reconstruirse cerca de su forma original. Esta consistencia se utiliza como una

restricción durante el entrenamiento para asegurarse que las transformaciones aprendidas sean coherentes en ambos sentidos.

Funcionamiento de CycleGAN

Durante el entrenamiento, las imágenes de ambos dominios se alimentan a sus respectivos generadores. El generador A a B transforma una imagen del dominio A en una imagen que debería parecerse al dominio B. Similarmente, el generador B a A hace lo opuesto. Los discriminadores evalúan si las imágenes generadas son indistinguibles de las imágenes reales de cada dominio.

Como en otras GANs, CycleGAN utiliza una función de pérdida adversaria para entrenar tanto los generadores como los discriminadores, promoviendo que los generadores creen imágenes cada vez más realistas.

Además de la pérdida adversaria, CycleGAN introduce una pérdida de consistencia de ciclo. Esta pérdida penaliza las transformaciones que no mantienen la consistencia cuando una imagen es transformada al otro dominio y luego de vuelta a su dominio original. Esta pérdida ayuda a preservar las características clave de la imagen original durante la transformación.




Figura 6.1: Diagrama del funcionamiento de CycleGAN

Fuente [7]

Aplicaciones

- Transferencia de estilo: Cambiar el estilo de las imágenes, por ejemplo, de una imagen foto-realista a un cuadro pintado por Van Gogh.
- Traducción de imágenes: Por ejemplo, como hacen los autores de CycleGAN, transformar imágenes de caballos en cebras.
- Restauración de fotos: Como colorear fotos en blanco y negro.

6.1.2. Pix2PixHD

Aunque no se va a utilizar este modelo en concreto para experimentar, hemos creído importante explicar este modelo, ya que sirve de inspiración para la futura creación de la arquitectura SPADE que representa el estado del arte.

Conceptos clave

Pix2PixHD se especializa en transformar mapas semánticos (donde cada píxel tiene una etiqueta de clase, como «cielo», «edificio», etc.) en imágenes realistas.

Al igual que su predecesor Pix2Pix, Pix2PixHD utiliza una arquitectura GAN, compuesta por un generador y por un discriminador. El generador intenta crear imágenes que parezcan reales, mientras que el discriminador intenta diferenciar entre imágenes reales y generadas. Encontramos en [6] el resto de detalles de la implementación.

Funcionamiento de Pix2PixHD

El generador en Pix2PixHD utiliza una red de convolución transpuesta para ir escalando progresivamente la resolución de la imagen de entrada, logrando así generar imágenes de alta resolución. Se utilizan módulos residuales para mejorar el flujo de información y estabilizar el entrenamiento.

A diferencia del modelo Pix2Pix original que utiliza un único discriminador, Pix2PixHD utiliza múltiples discriminadores que operan en diferentes escalas. Esto permite que el modelo se enfoque en detalles finos en varias resoluciones, mejorando la calidad y el realismo de las imágenes generadas.

Pérdida de características y VGG: Además de la pérdida adversaria estándar de GAN, Pix2PixHD utiliza una pérdida de características basada en una red VGG preentrenada. Esto ayuda a que las imágenes generadas se alineen mejor en términos de contenido y estilo con las imágenes objetivo.




Figura 6.2: Diagrama de la arquitectura del generador de Pix2PixHD

Fuente [6]




Figura 6.3: Diagrama del funcionamiento de pix2pixHD

Fuente [6]

6.1.3. SPADE

SPADE es una técnica avanzada en el ámbito del procesamiento de imágenes y la generación de contenido visual, particularmente utilizada en la generación de imágenes a partir de mapas semánticos. Se diseñó para mejorar la calidad y realismo de las imágenes generadas en tareas como la síntesis de escenas y la edición de imágenes. En nuestro caso, los mapas semánticos serán más sencillos, ya que solo tenemos dos clases que identificar, el fondo (background) y los pólipos. Los detalles de la implementación los podemos encontrar en [10]. SPADE toma algunas ideas del anterior estado del arte pix2pixHD.

Conceptos clave de SPADE

SPADE opera sobre mapas semánticos, que son representaciones de alto nivel de una escena, donde cada píxel está etiquetado con una categoría de objeto (como «cielo», «árbol», etc.).

Normalización en Redes Neuronales: Las técnicas de normalización tradicionales, como Batch Normalization, son comunes en las redes neuronales para estabilizar y acelerar el entrenamiento. Sin embargo, estas técnicas tienden a eliminar información espacial importante que es crucial para tareas de síntesis de imágenes.

Funcionamiento de SPADE

SPADE preserva la información espacial de los mapas semánticos al modificar el proceso de normalización en las redes generativas. En lugar de normalizar los mapas de características de manera uniforme, SPADE los ajusta de forma adaptativa según la información semántica de cada píxel.

La red utiliza lo que se llama «bloques SPADE» en varias capas. Cada bloque SPADE toma un mapa semántico como entrada y aprende a generar parámetros de escala (α) y desplazamiento (β) específicos para cada ubicación espacial. Estos parámetros se utilizan para denormalizar (modificar) los mapas de características normalizados de la red, permitiendo que la generación de la imagen mantenga y respete las características semánticas de la entrada.

SPADE se integra comúnmente con arquitecturas de redes generativas adversarias (GANs). El generador en una GAN con SPADE utiliza bloques SPADE para producir imágenes realistas a partir de los mapas semánticos, mientras que el discriminador evalúa la autenticidad de las imágenes generadas.




Figura 6.4: Diagrama de la arquitectura de SPADE

Fuente [10]

En la siguiente figura podemos ver las diferencias entre un bloque de normalización Batch tradicional y un bloque SPADE en el cual ajusta los parámetros según la información semántica.




Figura 6.5: Normalización SPADE vs. tradicional

Fuente [10]

6.2. Entrenamiento

6.3. Preparación de los datos

6.3.1. Creación de máscaras

Para entrenar nuestros modelos de aumentación primero debemos generar máscaras a partir de las anotaciones de nuestras cajas delimitadoras. Para este fin se ha diseñado el script `create masks.py` destinado a generar máscaras binarias a partir de nuestras anotaciones. Estas máscaras binarias son imágenes donde los píxeles de los objetos de interés están marcados (con 255, aunque si se quisiera en binario solo hace falta substituir el valor por 1) y el resto del fondo está sin marcar (con valor 0).

Funcionalidad:

■ Función `create mask from bounding boxes`:

- **Objetivo:** convierte los cuadros delimitadores en una máscara binaria
- **Entradas:**
 - **image shape:** forma de la imagen original para crear una matriz para la máscara del mismo tamaño.
 - **bounding boxes:** Lista de cuadros delimitadores (coordenadas) de los objetos en la imagen.
- **Proceso:** La función crea una matriz de ceros del tamaño de la imagen. Para cada cuadro delimitador, los píxeles correspondientes en la matriz se establecen en 255 (o 1), marcando así la presencia del objeto.

■ **Función process images in folder:**

- **Objetivo:** Procesar todas las imágenes en un directorio y generar las máscaras correspondientes
- **Entradas:**
 - **images folder:** Ruta al directorio que contiene las imágenes.
 - **annotations folder:** Ruta al directorio que contiene archivos de anotaciones.
 - **mask save dir:** directorio donde se guardan las máscaras generadas.
- **Proceso:** Para cada imagen en el directorio, esta función lee su archivo de anotación correspondiente, genera una máscara utilizando 'create mask from bounding boxes' y guarda la máscara en 'mask save dir'.

■ **Función process all videos:**

- **Objetivo:** Aplicar 'process images in folder' a todos los videos o conjuntos de imágenes en un directorio raíz
- **Entradas:**
 - **root dir:** Ruta al directorio raíz que contiene subdirectorios de imágenes y anotaciones
- **Proceso:** Itera a través de cada subdirectorio (cada uno representando un video o conjunto de imágenes) y llama a 'process images in folder' para cada uno.

El script establece la ruta al directorio del conjunto de datos y llama a 'process all videos' para los directorios de entrenamiento y prueba. Esto resulta en la creación de máscaras para todas las imágenes en el conjunto de datos.


Este paso de convertir las anotaciones en un formato de máscara binaria es un paso crucial para utilizar-lo en la generación de imágenes mediante métodos como CycleGAN.

6.3.2. Transformación de directorios

El modelo CycleGAN requiere una estructura de directorios específica para funcionar correctamente. Necesitamos separar las imágenes y sus correspondientes máscaras en directorios de entrenamiento y prueba. Esto es crucial porque el modelo aprende a diferenciar y generar nuevas imágenes basándose en estas categorías. El script 'copy files to cyclegan structure.py' automatiza el proceso de reorganización de los datos existentes en la estructura requerida por CycleGAN.

Estructura original del dataset de Detección de pólipos

El siguiente árbol representa la estructura de directorios de la que partiremos para generar la estructura que necesitamos para entrenar nuestro modelo de generación de imágenes. El conjunto de datos comprende dos directorios principales: 'Images' y 'Masks'. Cada directorio contiene subdirectorios que corresponden a diferentes números de videos, los cuales contienen los respectivos archivos de imagen y máscara.



Estructura del dataset para el entrenamiento de CycleGAN

El siguiente diagrama muestra la estructura de archivos después de ser reorganizada para usarlo en el entrenamiento de un modelo CycleGAN. Los datos se dividen en cuatro directorios principales: 'trainA' y 'trainB' para los datos de entrenamiento y 'testA' y 'testB' para los datos de prueba. 'trainA' y 'testA' contienen imágenes de máscaras, mientras que 'trainB' y 'testB' contienen las imágenes originales correspondientes.

```

datasets
├── PolypDetection Dataset
│   ├── trainA
│   │   └── Masks for training
│   ├── trainB
│   │   └── Images for training
│   ├── testA
│   │   └── Masks for testing
│   └── testB
│       └── Images for testing

```

Funcionamiento del script

■ Parámetros de la función:

- **root dir:** Este es el directorio raíz donde se encuentran los datos originales. Se espera que contenga subdirectorios para imágenes y máscaras.
- **target dir:** Es el directorio de destino donde queremos organizar los datos según la estructura requerida por CycleGAN.
- **mode:** Puede ser 'train' o 'test', indicando si estamos procesando datos para entrenamiento o para prueba.

■ Creación y preparación de directorios:

El script crea directorios para entrenamiento y prueba ('trainA', 'trainB', 'testA', 'testB') en el 'target dir'. 'A' representa las máscaras y 'B' las imágenes originales.

■ Proceso de copia de archivos:

- El script recorre cada subdirectorio en root dir. Por cada subdirectorio, encuentra las imágenes y las máscaras correspondientes.
- Para cada archivo de máscara e imagen se renombran (para mantener un rastreo claro de su origen) y se copian en el directorio correspondiente ('trainA', 'trainB', 'testA', 'testB'). Más específicamente se les añade al nombre del archivo, el nombre de la carpeta que los contiene, ya que en la carpeta de destino habrá imágenes de videos distintos juntos. Por lo tanto, y para evitar colisiones de nombres, se les ha añadido como prefijo el nombre de la carpeta.

Este script es un componente importante en la cadena de procesamiento de datos para el entrenamiento del modelo CycleGAN. Su automatización asegura la correcta organización de los datos, lo cual es crucial para el éxito del entrenamiento del modelo.

6.4. Generación de datos

A la hora de generar datos surgen una serie de preguntas como por ejemplo qué máscaras usar para generar estas imágenes que imitan a los pólipos reales, las siguientes opciones vienen a la mente.

- Usar máscaras reales:
 - Pros: Va a proporcionar la representación más precisa de los pólipos que se intentan detectar. La síntesis de imágenes resultará más realista.
 - Contras: Si la variabilidad en el conjunto de datos de máscaras reales es limitada, el modelo no va a poder aprender a generar suficiente diversidad en imágenes sintéticas
- Modificar máscaras reales:
 - Pros: Al aplicar transformaciones (por ejemplo, operaciones morfológicas, ligeras rotaciones o escalado, se puede aumentar la diversidad del conjunto de datos sin alejarse demasiado de los ejemplos del mundo real
 - Contras: Existe el riesgo de crear máscaras poco realistas si las modificaciones son demasiado extremas, lo que puede llevar a la generación de imágenes no plausibles
- Generar Máscaras aleatorias:
 - Pros: Este enfoque podría introducir potencialmente un alto grado de variabilidad y cubrir casos no presentes en el conjunto de datos
 - Contras: Las máscaras aleatorias pueden no ser representativas de las formas y tamaños reales de los pólipos, esto puede llevar a imágenes sintéticas que no reflejan escenarios reales. Esto podría dificultar la capacidad del modelo para aprender características significativas.

Teniendo todo esto en cuenta, seguramente lo que funcionará mejor es un enfoque equilibrado.

Otra consideración a tener en cuenta es el número de imágenes a generar, cuál es el número óptimo de imágenes a añadir a nuestro dataset? La manera más fácil de verlo es experimentando. Inicialmente, consideraremos aumentar el dataset con un 50-100 % del tamaño del dataset original para evaluar el impacto en el modelo. Si podemos observar mejoras podemos considerar generar más para ver si conseguimos obtener mejores resultados. Hay que tener en cuenta de no generar demasiadas imágenes que puedan provocar un overfitting a nuestros datos.

6.5. Problemas de convergencia

Los problemas más comunes a la hora de entrenar GANs son el *mode collapse* el cual ya habíamos mencionado anteriormente y los *vanishing gradients*. En esta sección entraremos en detalle en el mode collapse.

6.5.1. Mode collapse

El objetivo de las GANs es aprender una distribución de probabilidad compleja. La convergencia de las GANs implica que la probabilidad observada se acercará a la distribución línea base o real $P_{gen} \approx P_{real}$. El problema suele ser que el modelo no aprende a generar gran parte de los datos de entrenamiento, es decir, solo aprende a generar un subconjunto muy reducido de lo que ha aprendido durante el entrenamiento, a esto se le llama mode collapse. La razón de este problema la encontramos precisamente en la inicialización de las GANs. En un espacio de muchas dimensiones es difícil que la generación del «manifold» la superficie geométrica que describe los datos cubra todos los posibles modos. En el trabajo de [14], se describe con mayor detalle estos problemas de forma teórica, vamos a verlo e intentar explicarlo de forma más sencilla.

Supongamos que el generador es una función compuesta de transformaciones afines y de linealidades no puntuales, es decir, funciones de activación como puede ser una Rectified Linear Unit (ReLU), la función sigmoide o la tangente hiperbólica tanh. Para este caso, supongamos que las no-linearidades son de la forma $\delta(x) = 1[x < 0]c_1x + 1[x \geq 0]c_2x$, para alguna $c_1, c_2 \in R$, es decir, el input cuando sea mayor igual que 0 se multiplicará por el coeficiente, c_2 mientras que si es menor se multiplicará por el coeficiente c_1 . Entonces podemos representar la red generativa de la forma:

$$g(z) = M_n W_n \dots M_1 W_1 z, \quad (6.1)$$

Donde M_i son las matrices diagonales que dependen de z y estas tienen entradas diagonales c_1 o c_2 y que W_i contiene las transformaciones afines. Supongamos M es el conjunto de todas las matrices diagonales con entradas c_1 o c_2 :

$$g(Z) \subseteq \bigcup_{M_i \in M} M_n W_n \dots M_1 W_1 Z, \quad (6.2)$$

Esto es una unión finita de manifolds lineales. Nótese que en una SVD, (Singular Value decomposition), $W = U\sigma V$, las operaciones (multiplicando por σ y aplicando un cambio de base son difeomorfismos, es decir, es una función invertible que mapea un manifold diferenciable a otro, de tal manera que tanto la función como su inversa son diferenciables. Y añadiendo ceros a las nuevas coordenadas). Estas operaciones indican un ajuste de manifolds. El manifold generado $g(Z)$ se contendrá dentro de una unión contable de manifolds de baja dimensionalidad, por tanto, el manifold generado tiene medida 0 en X . Es decir, ocupa un espacio muy pequeño o negligible en la porción del espacio en la que está incrustado (embedded). El manifold de los datos reales podría estar lleno

del espacio de sampling. Por ese motivo es difícil cubrir todos los ejemplos, especialmente al principio del entrenamiento. Esta es la principal razón para el mode collapse al entrenar GANs. El manifold inicial no puede cubrir todos los ejemplos.

Para el segundo motivo, consideramos la generalización en las GANs que quiere decir que la población entre distribución generada y distribución real de los datos está muy cerca de la distancia empírica entre distribuciones empíricas. Es decir, queremos tanto que los datos generados por la GAN se acerquen a los datos reales observados (Distancia empírica) como también que la distribución generada se acerque a la distribución real de los datos en términos de propiedades estadísticas (p. ej. media, varianza, otras) a los datos reales.

Primero, asumamos que la función objetivo para el entrenamiento de las GANs es $E_{x \sim P_r}[\phi(D(x))] + E_{x \sim P_g}[\phi(1 - D(x))]$. También asumiremos que la función de medida se comprende en el rango $-\Delta$ a Δ , $F = \{D_v, v \in V\}$, $F = \{D_v, v \in V\}$ es la clase de discriminadores que son L-Lipschitz con respecto a los parámetros v . Y p denota el número de parámetros en v .

Sea μ, v dos distribuciones y $\hat{\mu}, \hat{v}$ sus versiones empíricas, cada una con al menos m muestras. Se muestra que con alta probabilidad, para cada discriminador D_v existe:

$$|E_{x \sim \mu}[\phi(D_v(x))] - E_{x \sim \hat{\mu}}[\phi(D_v(x))]| \leq \epsilon/2 \quad (6.3)$$

$$|E_{x \sim v}[\phi(1 - D_v(x))] - E_{x \sim \hat{v}}[1 - \phi(D_v(x))]| \leq \epsilon/2 \quad (6.4)$$

La demostración se encuentra en [4]. Entonces, podemos concluir que si $\hat{\mu}$ es la versión empírica de la distribución μ con m muestras, existe una constante universal c tal que cuando $m \geq (cp^2\Delta^2\log(LL_{\Phi}p/\epsilon))/\epsilon^2$, tenemos que con probabilidad de al menos $1 - \exp(-p)$, $d_{F,\Phi}(\mu, \hat{\mu}) \leq \epsilon$.

Muestra que una red de discriminador con p parámetros no puede distinguir una distribución μ y una distribución con soporte $\tilde{O}(p/\epsilon^2)$. Esto es, el discriminador de capacidad baja no puede detectar la falta de diversidad de las muestras. Las muestras de entrenamiento son muy dispersas y el espacio de muestras tiene una alta dimensionalidad. Por esto ocurre el mode collapse en las GANs. Esto nos lleva a concluir que en el entrenamiento de las GANs, los gradientes del generador no pueden llevar a generar el manifold para cubrir todos los ejemplos. Esto apunta, por lo tanto, a la segunda razón por el mode collapse en las GANs: el método de entrenamiento no puede recuperarse del mode collapse.

Existen métodos que intentan aliviar esos problemas como el SSGAN.

Capítulo 7

Análisis del dataset

Objetivo y Metodología:

El objetivo principal de esta sección del análisis de datos es comprender las propiedades de las cajas delimitadoras (bounding boxes) en nuestro conjunto de datos. Estas cajas representan las ubicaciones de los objetos de interés (posiblemente pólipos) en las imágenes médicas. Comprender su distribución, dimensiones y ubicaciones relativas es esencial para el desarrollo de un modelo de detección de objetos robusto y preciso.

7.1. Análisis de las cajas delimitadoras

Inicialmente, extraemos todas las cajas delimitadoras de nuestro conjunto de datos utilizando la función 'get all bounding boxes'. Esto nos permite analizar y visualizar las dimensiones y posiciones de los objetos dentro de las imágenes.

Función 'get all bounding boxes': Esta función se aprovecha de que la clase CustomDataset ya conoce la estructura de los datos y extrae la información de las cajas delimitadoras a partir de esa clase. Itera a través de todos los elementos y devuelve una lista con todas las cajas.

7.1.1. Implementación del análisis de datos

Cálculo de centros de cajas

Mediante 'get bbox centers' calculamos los centros de estas cajas delimitadoras. Este paso es vital para entender dónde tienden a ubicarse los objetos dentro de las imágenes, lo cual puede indicar, por ejemplo, si hay una tendencia de los pólipos a aparecer en regiones específicas

Función 'get bbox centers': Esta función toma una lista de cajas delimitadoras y a partir de las posiciones xmin ymin xmax y ymax calcula el centro de las cajas iterando sobre la lista.

Agrupamiento con K-means

Se aplican técnicas de agrupamiento (clustering) para identificar patrones en los datos de las cajas delimitadoras. Utilizamos el algoritmo K-means, una técnica de aprendizaje no supervisado, para agrupar los centros de las cajas en diferentes categorías. Este proceso se facilita con funciones como 'calculate wcss' y 'cluster bounding boxes'. El primero calcula la suma de cuadrados dentro del grupo para diferentes números de grupos, lo que nos ayuda a determinar el número óptimo de grupos.

Función 'calculate wcss': Esta función calcula la suma de cuadrados intra-clusters para diferentes números de clústers usando el algoritmo de clustering K-means.

- Parámetros:
 - data: lista de los centros de las cajas delimitadoras.
 - max k: máximo número de clusters que se van a probar.
- Proceso:
 - La función inicia un bucle que empieza desde 1 hasta 'max k'
 - Para cada valor 'k' se ejecuta el algoritmo K-Means sobre los datos 'data'
 - kmeans.inertia: Obtiene la suma de las distancias al cuadrado de las muestras a su centro de clúster más cercano. Este valor es el WCSS para el número de clústeres 'k'
 - Almacenamos el valor del WCSS para este número de clústeres en una lista.

Función 'cluster bounding boxes': El objetivo de esta función es agrupar los centros de las cajas delimitadoras usando el algoritmo de clustering K-means. Esto es útil para identificar patrones comunes en la posición de los objetos dentro de las imágenes.

- Parámetros
 - bbox centers: Lista de los centros de las cajas delimitadoras. En el formato [xcenter, ycenter].
 - n clusters: El número de clústeres a formar.
- Proceso:
 - Inicializa y aplica el algoritmo de K-Means con el valor 'n clusters' y con una semilla aleatoria para reproducibilidad 'random state = 0'
 - Obtención de resultados:
 - 'kmeans.cluster centers ': Recupera los centros de los clústeres calculados por K-Means, que representan el "centro" promedio de cada clúster

- `'kmeans.labels'`: Obtiene las etiquetas de clúster para cada punto de datos, indicando a qué clúster pertenece cada centro de caja delimitadora.

■ Retorno:

- `'centers'`: Los centros de los clústeres calculados
- `'kmeans.labels'`: Las etiquetas de clúster para cada centro de caja delimitadora

Visualización de resultados

Para interpretar los resultados del análisis se realizan varias visualizaciones. Por ejemplo, se utiliza `'plot elbow'` para mostrar el método del codo, que ayuda en la selección del número óptimo de clústers para K-means. Las funciones `'plot cluster centers'` y `'plot cluster centers with bbox centers'` se utilizan para visualizar los centros de los clústeres y cómo se relacionan estos con los centros de las cajas delimitadoras.

Función `'plot elbow'`

■ Parámetro:

- `'wcss'`: Una lista de valores de WCSS. Cada valor en esta lista representa la suma de cuadrados dentro del clúster para un número específico de clústeres. Por ejemplo, el primer elemento es el WCSS para 1 clúster, el segundo para 2 clústeres, y así sucesivamente.

■ Proceso:

- Dada la lista de valores, crea un gráfico de línea que muestra cómo cambia el valor de WCSS a medida que aumenta el número de clústeres.
- Configura el estilo de la gráfica, añade títulos y demás.

Función `'plot cluster centers'`:

■ Parámetros:

- `'centers'`: Una lista que contiene las coordenadas de los centros de los clústeres. Los centros son de la forma: `(xcenter, ycenter)`

■ Proceso:

- Utiliza un gráfico de dispersión `'scatter plot'` para dibujar los centros de los clústeres

Función `'plot cluster centers with bbox centers'`: Idéntico a `'plot cluster centers'` pero además muestra los centros de todas las cajas delimitadoras.

■ Parámetros:

- 'centers': Lista que contiene los centros de los clústeres. Cada elemento es un par de coordenadas (x,y).
- 'bbox centers': lista que contiene los centros de las cajas delimitadoras. Al igual que 'centers' es un par de coordenadas (x,y).

■ Proceso:

- Utiliza un gráfico de dispersión para mostrar los centros de las cajas delimitadoras.
- De manera similar, muestra los centros de los clústeres en color rojo.

Función 'plot density of bbox centers':

■ Parámetros:

- bbox centers: Una lista que contiene las coordenadas de los centros de las cajas delimitadoras.

■ Proceso:

- Crea un gráfico de densidad utilizando KDE, Kernel Density Estimate.
- El gráfico de densidad muestra las regiones donde hay mayor concentración de centros.

Función 'plot density of bbox centers with clusters': Idéntico a plot density of bbox centers pero con centros de clusters.

7.1.2. Resultados del análisis

Método del codo

Se calcula la suma de cuadrados dentro del cluster (WCSS) para un rango de números de clusters. Se busca un 'codo' en el gráfico, que indica un cambio en la tasa de disminución y sugiere un número óptimo de clusters.

En nuestro caso podemos ver que el método del codo muestra un punto de inflexión que sugiere que el número óptimo de clusters se encuentra en 3. Esto sugiere que las bounding boxes se pueden agrupar de manera efectiva en tres clusters.




Figura 7.1: Método del codo

Fuente: Creación propia

Análisis de Silueta

En el análisis de silueta se calcula la puntuación de silueta para el mismo rango de números de clústeres. Una puntuación alta indica que el clúster está bien separado de otros clústeres.

Los resultados del análisis de silueta complementan el resultado anterior al proporcionar un sentido de cuán distintos son estos clústeres entre sí. En este caso vemos que los valores son altos para 8, 6 y para 2 clústeres. Dado que 8 clústeres parece una separación compleja y sigue dando buenos resultados, nos decantaremos por usar ese número de clústeres junto al resultado anterior de 3 clústeres.




Figura 7.2: Análisis de silueta

Fuente: Creación propia

Gráficos de los centros de los clústeres

Los resultados muestran que los clusters están distribuidos de manera equidistante a lo largo del espacio de las imágenes. Este patrón equidistante sugiere que los polipos están uniformemente distribuidos en términos de ubicación dentro de las imágenes.




Figura 7.3: Centros de 3 clusters




Figura 7.4: Centros de 8 clusters

Fuente: Creación propia

Fuente: Creación propia

Para poder visualizar mejor el contexto de los datos mostramos los centros de los clústeres junto con los de las cajas delimitadoras en la misma gráfica. Esto nos permite ver si los centros de los clústeres se encuentran cerca de los centros de las bounding boxes.

Resultados:

Parece que los centros de los clústeres se encuentran cerca de los centros de las bounding boxes, pero no podemos apreciarlo bien porque hay muchos centros de bounding boxes acumulados. Por este motivo sería interesante probar con un gráfico de densidad.




Figura 7.5: Cajas delimitadoras con 3 clusters

Fuente: Creación propia




Figura 7.6: Cajas delimitadoras con 8 clusters

Fuente: Creación propia

Gráfico de densidad

El gráfico de densidad de los centros de las cajas delimitadoras es una herramienta visual importante para entender la distribución espacial de los objetos (en nuestro caso, pólipos) dentro de las imágenes del conjunto de datos. A continuación, se explica detalladamente este gráfico y su interpretación:

Expectativa inicial:

- Una suposición inicial podría ser que los centros de los pólipos (representados por los centros de las cajas delimitadoras) se localizan principalmente cerca de los bordes de las imágenes. Esto se basaría en la comprensión de que las imágenes de colonoscopias a menudo presentan pólipos en los bordes del campo de visión debido a la naturaleza tubular del colon.

Resultados observados:

- Contrariamente a la expectativa, el gráfico de densidad muestra que los centros de las cajas delimitadoras se concentran más hacia el centro de las imágenes.
- Este resultado es significativo porque indica que los pólipos tienden a estar localizados en la parte central de las imágenes de colonoscopia en lugar de en los bordes, como se podría haber supuesto inicialmente.




Figura 7.7: Gráfico de densidad de cajas delimitadoras

Fuente: Creación propia




Figura 7.8: Gráfico de densidad de cajas delimitadoras con 3 clusters

Fuente: Creación propia




Figura 7.9: Gráfico de densidad de cajas delimitadoras con 8 clusters

Fuente: Creación propia

Capítulo 8

Análisis y Resultados Experimentales

8.1. Detección

Usando la función 'test model.py' podemos seleccionar el modelo que queremos probar y generar predicciones sobre datos nunca vistos por el modelo durante el entrenamiento, en las siguientes imágenes podemos ver dos imágenes a modo de ejemplo de las predicciones que ha hecho el modelo. Las cajas delimitadoras verdes representan las señaladas por profesionales médicos como pólipos, las cajas delimitadoras rojas representan las predicciones del modelo.




Figura 8.1: Detección de pólipos en colonoscopia
Fuente: Creación propia




Figura 8.2: Detección de pólipos en colonoscopia
Fuente: Creación propia

Como se puede ver, el modelo tiene margen de mejora, pero claramente se ve que ha aprendido algo y realmente no hace predicciones de forma aleatoria.

Las siguientes tablas son las métricas de evaluación obtenidas utilizando FasterRCNN con la librería pycocotools:

BATCH SIZE	LR	WEIGHT DECAY	NUM EPOCHS	epoch	AP 50 95 all	AP 50 all
4	2e-05	0,0045	3	0	0,00727	0,029
4	0,00016	0,00743	9	2	0,07838	0,21619
2	0,00795	0,00331	1	0	0,02249	0,08332
4	0,00231	0,00376	1	0	0,06846	0,20579
4	0,0053	2e-05	3	2	0,09541	0,20897
8	6e-05	0,00234	3	0	0,01599	0,05141
2	0,00169	0,00039	7	6	0,09255	0,21319
2	0,03084	0,00013	2	0	0,04535	0,11523
8	0,00273	0,00649	5	2	0,05247	0,16259
4	0,03758	0,00254	1	0	0,00165	0,00779
BATCH SIZE	LR	WEIGHT DECAY	NUM EPOCHS	epoch	AP 75 all	AP 50 95 small
4	2e-05	0,0045	3	0	0,00191	0,0
4	0,00016	0,00743	9	2	0,04331	0,0
2	0,00795	0,00331	1	0	0,00476	0,0
4	0,00231	0,00376	1	0	0,02373	0,0
4	0,0053	2e-05	3	2	0,07582	0,0
8	6e-05	0,00234	3	0	0,00573	0,0
2	0,00169	0,00039	7	6	0,06757	0,0
2	0,03084	0,00013	2	0	0,03028	0,0
8	0,00273	0,00649	5	2	0,01448	0,0
4	0,03758	0,00254	1	0	0,00028	0,0

BATCH SIZE	LR	WEIGHT DECAY	NUM EPOCHS	epoch	AP 50 95 medium	AP 50 95 large
4	2e-05	0,0045	3	0	7e-05	0,01978
4	0,00016	0,00743	9	2	0,02268	0,18679
2	0,00795	0,00331	1	0	0,00853	0,04887
4	0,00231	0,00376	1	0	0,01775	0,16709
4	0,0053	2e-05	3	2	0,02259	0,23849
8	6e-05	0,00234	3	0	0,00075	0,04192
2	0,00169	0,00039	7	6	0,01784	0,24212
2	0,03084	0,00013	2	0	0,00347	0,16284
8	0,00273	0,00649	5	2	0,01332	0,14125
4	0,03758	0,00254	1	0	5e-05	0,00386
BATCH SIZE	LR	WEIGHT DECAY	NUM EPOCHS	epoch	AR 50 95 all maxDets 1	AR 50 95 all maxDets 10
4	2e-05	0,0045	3	0	0,0174	0,04329
4	0,00016	0,00743	9	2	0,11398	0,14875
2	0,00795	0,00331	1	0	0,05264	0,08592
4	0,00231	0,00376	1	0	0,09523	0,14245
4	0,0053	2e-05	3	2	0,12269	0,14711
8	6e-05	0,00234	3	0	0,03218	0,06871
2	0,00169	0,00039	7	6	0,12455	0,13906
2	0,03084	0,00013	2	0	0,08585	0,13931
8	0,00273	0,00649	5	2	0,07886	0,12368
4	0,03758	0,00254	1	0	0,00873	0,03152

BATCH SIZE	LR	WEIGHT DECAY	NUM EPOCHS	epoch	AR 50 95 all maxDets 100	AR 50 95 small maxDets 100
4	2e-05	0,0045	3	0	0,04856	0,0
4	0,00016	0,00743	9	2	0,14926	0,00068
2	0,00795	0,00331	1	0	0,08607	0,0
4	0,00231	0,00376	1	0	0,1446	0,00017
4	0,0053	2e-05	3	2	0,14718	0,00017
8	6e-05	0,00234	3	0	0,0793	0,0
2	0,00169	0,00039	7	6	0,13906	0,0
2	0,03084	0,00013	2	0	0,14767	0,00045
8	0,00273	0,00649	5	2	0,125	0,0
4	0,03758	0,00254	1	0	0,03501	0,0
BATCH SIZE	LR	WEIGHT DECAY	NUM EPOCHS	epoch	AR 50 95 medium maxDets 100	AR 50 95 large maxDets 100
4	2e-05	0,0045	3	0	0,0097	0,12685
4	0,00016	0,00743	9	2	0,07092	0,30628
2	0,00795	0,00331	1	0	0,04171	0,1737
4	0,00231	0,00376	1	0	0,08199	0,27511
4	0,0053	2e-05	3	2	0,05625	0,33036
8	6e-05	0,00234	3	0	0,02677	0,18497
2	0,00169	0,00039	7	6	0,04654	0,32059
2	0,03084	0,00013	2	0	0,06511	0,3215
8	0,00273	0,00649	5	2	0,05126	0,27996
4	0,03758	0,00254	1	0	0,00162	0,10214

Evaluación de la precisión del Modelo: Las columnas AP 50 95 all, AP 50 all, AP 75 all, AP 50 95 small, AP 50 95 medium, y AP 50 95 large se refieren a la precisión promedio (AP) del modelo en diferentes umbrales. Por ejemplo, AP 50 95 all se refiere a una medida de precisión promedio en todos los tamaños de objetos, para umbrales IoU (intersection over Union) desde 0.50 hasta 0.95. Un valor más alto en estas métricas indica un mejor rendimiento en la detección.

Evaluación del Recall del Modelo: Las columnas que empiezan con AR muestran el recall promedio del modelo. Estos valores indican qué tan bien el modelo es capaz de detectar todos los objetos relevantes.

Rendimiento en diferentes tamaños de objetos: Las métricas específicas para small, medium y large indican cómo se desempeña en la detección de objetos de diferentes tamaños.

Las métricas más relevantes para evaluar el rendimiento general del modelo son:

- AP 50 95 all: que es una métrica general que combina diferentes niveles de IoU (Intersection over Union) desde 0.50 hasta 0.95 para todos los tamaños de objetos.
- AR 50 95 all maxDets 100: que es una medida de qué tan bien el modelo detecta los objetos relevantes con un máximo de 100 detecciones.

Para escoger los mejores hiperparámetros se ha decidido por calcular el f score (el promedio armónico de precisión y recall) utilizando las dos métricas anteriores.

Model	BATCH SIZE	LR	WEIGHT DECAY	NUM EPOCHS	epoch	F1 score
FasterRCNN	4	2e-05	0,0045	3	0	0,01264
FasterRCNN	4	0,00016	0,00743	9	2	0,10278
FasterRCNN	2	0,00795	0,00331	1	0	0,03566
FasterRCNN	4	0,00231	0,00376	1	0	0,09293
FasterRCNN	4	0,0053	2e-05	3	2	0,11577
FasterRCNN	8	6e-05	0,00234	3	0	0,02662
FasterRCNN	2	0,00169	0,00039	7	6	0,11113
FasterRCNN	2	0,03084	0,00013	2	0	0,06939
FasterRCNN	8	0,00273	0,00649	5	2	0,07391
FasterRCNN	4	0,03758	0,00254	1	0	0,00316

Como podemos ver, el mejor modelo es el quinto con los siguientes hiperparámetros:

- Batch 4
- LR 0,0053
- Weight decay 2e-05
- Num epochs 3
- epoch 2

- F1 score 0,1158

Con la información recopilada podemos deducir algunas conclusiones:

- Parece ser que el modelo podría estar teniendo dificultades para detectar objetos con la precisión deseada, especialmente los objetos más grandes.
- Los valores bajos de AP y AR sugieren que podría ser necesario un ajuste adicional de hiperparámetros, un entrenamiento más prolongado (más épocas), o que el modelo podría beneficiarse de un conjunto de datos de entrenamiento más amplio o mejor anotado.
- La variación en los hiperparámetros muestra que el rendimiento del modelo es sensible a estos cambios, lo cual es típico en el aprendizaje profundo

A primera vista parecería que detecta bastante bien los pólipos, pero viendo las puntuaciones vemos que hay bastante margen de mejora. Sin embargo, si inspeccionamos los archivos intermedios de las predicciones, podemos ver que el 'score' de las predicciones es considerablemente bajo, es decir, el modelo no está muy seguro, generalmente en las predicciones que hace.

8.2. Aumentación de datos

Los resultados de la aumentación de datos no han dado los resultados esperados debido a la naturaleza de CycleGAN, los cambios que debe aplicar a una máscara son demasiado grandes como para que funcione como se espera. Este desafío resalta la importancia de elegir técnicas de aumentación de datos adecuadas para cada tipo específico de imagen médica y su patología. Sin embargo, siempre se podría entrenar con mayor número de hiperparámetros para ver si mejora la generación, pero eso está fuera del alcance de este proyecto.

A continuación podemos ver un ejemplo de output del CycleGAN entrenado. La notación de las imágenes es la que sigue:

- **real A:** Esta se refiere a las imágenes reales del dominio A. En un entorno de CycleGAN, hay típicamente dos dominios A i B. Las del entorno A se usan como input para generar imágenes en el dominio B.
- **fake B:** Estas imágenes son las generadas por CycleGAN cuando convierte imágenes desde el dominio A al dominio B.
- **rec A:** Son las 'reconstruidas A' son el resultado de tomar imágenes fake B (que han sido transformadas al dominio B) i intentar volverlas a convertir al dominio A. Esta es la parte del ciclo de consistencia de CycleGAN, esto ayuda al modelo a aprender características clave.
- **real B:** Parecido a real A, las imágenes 'real B' son las imágenes reales del dominio B. Estas se usaran para generar las imágenes de A y también se usaran para evaluar.

- **fake A:** Estas son las imágenes que CycleGAN convierte desde imágenes del dominio B al dominio A.
- **rec B:** 'Reconstrucción B' estas son las imágenes creadas tomando 'fake A' y transformándolas de vuelta al dominio B. Esta es, de nuevo, la parte del ciclo de consistencia de CycleGAN.

101_0042_mask




Figura 8.3: Resultados del entrenamiento de la red CycleGAN

Fuente: Creación propia

Capítulo 9

Conclusiones

9.1. Conocimientos adquiridos

A lo largo del desarrollo de este proyecto, se han adquirido conocimientos y habilidades en diversas áreas de la ciencia de datos, la visión por computadora y el aprendizaje profundo. Entre los conocimientos más significativos se encuentran:

- Manejo de conjuntos de datos de imágenes médicas: Se desarrolló una comprensión profunda sobre cómo manejar y procesar datos de imágenes médicas, en especial para la detección de pólipos en imágenes de colonoscopias. Esto incluyó técnicas para la anotación de imágenes, preprocesamiento y aumento de datos.
- Aplicación de Redes Neuronales en Visión por Computadora: Se adquirieron habilidades prácticas en la implementación y entrenamiento de modelos de redes neuronales convolucionales, como Faster R-CNN, SSD y RetinaNet, para la detección de objetos.
- Uso de Herramientas de Aprendizaje Profundo y Ciencia de Datos: Se dominaron herramientas y bibliotecas como PyTorch, Matplotlib, Numpy, así como plataformas de optimización de hiperparámetros como Optuna y Ray Tune.
- Conocimientos en Transferencia de Estilo y Generative Adversarial Networks (GANs): A través del uso y estudio tanto de CycleGAN como de sus alternativas, para la transformación de estilo en imágenes, se obtuvieron conocimientos sobre redes generativas antagónicas y su aplicación práctica.

9.2. Resultados del proyecto

El proyecto logró implementar con éxito un sistema de detección de pólipos en imágenes de colonoscopias utilizando técnicas avanzadas de visión por computadora y aprendizaje profundo. Los modelos entrenados demostraron una capacidad notable para identificar y localizar pólipos, lo cual es un paso significativo hacia la mejora de las herramientas de diagnóstico en medicina.

- Optimización de modelos: Se consiguió afinar los modelos a través de la optimización de hiperparámetros, lo que resultó en una mejora significativa en el rendimiento en comparación con las iteraciones iniciales.
- Visualización de Datos y Resultados: Se desarrollaron habilidades para visualizar tanto los datos de entrada como las salidas de los modelos, proporcionando una comprensión intuitiva del rendimiento del modelo y las áreas de mejora.

9.3. Limitaciones del estudio

- Diversidad de Datos: A pesar de la eficacia del conjunto de datos utilizado, su diversidad podría ser ampliada. Más variaciones en las características de los pólipos y en las imágenes de colonoscopia enriquecerían el entrenamiento de los modelos.
- Complejidad Computacional: Algunos de los modelos implementados requerían una gran capacidad computacional. Esta demanda de recursos es un obstáculo en un entorno con limitaciones tecnológicas.
- Acceso tardío a Recursos Computacionales del BSC: Una limitación significativa fue el acceso tardío a los recursos computacionales del Barcelona Supercomputing Center (BSC). Esta demora en el acceso restringió el tiempo disponible para el entrenamiento intensivo de modelos, lo que ha perjudicado a la planificación del proyecto.

9.4. Reflexiones finales

Este proyecto ha sido una oportunidad invaluable para aplicar teorías y conceptos de aprendizaje automático y visión por computadora en un contexto práctico y con impacto potencial en el campo médico. Ha desafiado y expandido mis capacidades técnicas, así como mi comprensión de las aplicaciones prácticas y limitaciones de la tecnología moderna de IA en la salud. Este trabajo sienta las bases para futuras investigaciones y desarrollos en el área, y abre la puerta a nuevas posibilidades en el diagnóstico y tratamiento médico asistido por IA.

Capítulo 10

Trabajo Futuro

- Desarrollar y programar un generador de máscaras, utilizando las conclusiones obtenidas del análisis de los datos.
- Implementar y probar la técnica SPADE (Spatially-Adaptive (DE)Normalization) para la aumentación de datos. SPADE podría ofrecer mejoras significativas en la calidad de las imágenes generadas, respecto a CycleGAN.
- Optimizar la red de segmentación mediante herramientas como Optuna o RayTune, explorando con mayor cantidad de hiperparámetros.
- Extender la optimización de CycleGAN con un conjunto más extenso de hiperparámetros. Esto podría ayudar a encontrar un punto en el que la generación de imágenes sea suficientemente buena para ser utilizada en detección de pólipos.
- Realizar pruebas, optimización y evaluación de los modelos de RetinaNet y SSD. Aunque no ha sido posible completar estas tareas dentro del marco temporal del proyecto actual, la implementación ya está lista, y solo falta entrenar y ajustar estos modelos para evaluar su rendimiento.
- Diseñar y desarrollar una interfaz de usuario intuitiva y fácil de usar para el sistema. Esto facilitaría la interacción de los usuarios con la herramienta.

Bibliografía

- [1] Ian J. Goodfellow et al. *Generative Adversarial Networks*. 2014. arXiv: 1406.2661 [stat.ML].
- [2] Wei Liu et al. *SSD: Single Shot MultiBox Detector*. Dic. de 2015. URL: <https://arxiv.org/abs/1512.02325>.
- [3] Shaoqing Ren et al. *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. Jun. de 2015. URL: <https://arxiv.org/abs/1506.01497>.
- [4] Sanjeev Arora et al. *Generalization and Equilibrium in Generative Adversarial Nets (GANs)*. Mar. de 2017. URL: <https://arxiv.org/abs/1703.00573>.
- [5] Tsung-Yi Lin et al. *Focal Loss for Dense Object Detection*. Ago. de 2017. URL: <https://arxiv.org/abs/1708.02002>.
- [6] Ting-Chun Wang et al. *High-Resolution Image Synthesis and Semantic Manipulation with Conditional GANs*. Nov. de 2017. URL: <https://arxiv.org/abs/1711.11585>.
- [7] Jun-Yan Zhu et al. *Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks*. Mar. de 2017. URL: <https://arxiv.org/abs/1703.10593>.
- [8] Yongcheng Jing et al. *Neural Style Transfer: A Review*. 2018. arXiv: 1705.04058 [cs.CV].
- [9] Diederik P. Kingma y Max Welling. «An Introduction to Variational Autoencoders». En: *Foundations and Trends® in Machine Learning* 12.4 (2019), págs. 307-392. DOI: 10.1561/22000000056. URL: <https://doi.org/10.1561/22000000056>.
- [10] Taesung Park et al. *Semantic Image Synthesis with Spatially-Adaptive Normalization*. Mar. de 2019. URL: <https://arxiv.org/abs/1903.07291>.
- [11] Sumit Dhawan y Shailender Kumar. «Improving resolution of images using Generative Adversarial Networks». En: *2020 4th International Conference on Electronics, Communication and Aerospace Technology (ICECA)*. 2020, págs. 880-887. DOI: 10.1109/ICECA49313.2020.9297414.

- [12] Mar. de 2021. URL: <https://www.bristows.com/news/artificial-intelligence-assisted-medical-imaging-and-the-gdpr/>.
- [13] Yiting Ma et al. *LDPolypVideo Benchmark: A Large-Scale Colonoscopy Video Dataset of Diverse Polyps*. Ene. de 2021. URL: https://link-springer-com.recursos.biblioteca.upc.edu/chapter/10.1007/978-3-030-87240-3_37.
- [14] Kaifeng Zhang. *On Mode Collapse in Generative Adversarial Networks*. Ene. de 2021. URL: https://link-springer-com.recursos.biblioteca.upc.edu/chapter/10.1007/978-3-030-86340-1_45.
- [15] Soumya Gupta et al. «UNet-eVAE: Iterative Refinement Using VAE Embodied Learning for Endoscopic Image Segmentation». En: *Machine Learning in Medical Imaging*. Ed. por Chunfeng Lian et al. Cham: Springer Nature Switzerland, 2022, págs. 161-170. ISBN: 978-3-031-21014-3.
- [16] James Jordon et al. *Synthetic Data – what, why and how?* 2022. arXiv: 2205.03257 [cs.LG].
- [17] Britt B.S. L. Houwen et al. «Comprehensive review of publicly available colonoscopic imaging databases for artificial intelligence research: availability, accessibility, and usability». En: *Gastrointestinal Endoscopy* 97.2 (feb. de 2023), 184-199.e16. DOI: 10.1016/j.gie.2022.08.043.
- [18] ifttt-user. *Diffusion Models vs. GANs vs. VAEs: Comparison of Deep Generative...* Mayo de 2023. URL: <https://towardsai.net/p/machine-learning/diffusion-models-vs-gans-vs-vaes-comparison-of-deep-generative-models>.
- [19] Richard Osuala et al. «medigan: a Python library of pretrained generative models for medical image synthesis». En: *Journal of Medical Imaging* 10.06 (feb. de 2023). DOI: 10.1117/1.jmi.10.6.061403. URL: <https://doi.org/10.1117/2F1.jmi.10.6.061403>.
- [20] En: *Google for Developers* (). URL: https://developers.google.com/machine-learning/gan/gan_structure.
- [21] URL: <https://www.jobted.es/salario>.
- [22] URL: <https://sede.agenciatributaria.gob.es/Sede/impuesto-sobre-sociedades/que-base-imponible-se-determina-sociedades/amortizaciones.html?faqId=42c3904421205710VgnVCM100000dc381e0aRCRD>.
- [23] URL: <https://tarify.es/noticias/cual-consumo-ordenador-sobremesa?ssp=1&setlang=es-ES&safesearch=moderate>.
- [24] URL: <https://www.niddk.nih.gov/health-information/informacion-de-la-salud/enfermedades-digestivas/polipos-colon/diagnostico?ssp=1&setlang=es-ES&safesearch=moderate>.
- [25] URL: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX%3A32016R0679>.
- [26] URL: <https://ar5iv.labs.arxiv.org/html/1504.08083>.

- [27] Ediciones El País. *Calculadora sueldo neto*. URL: https://cincodias.elpais.com/herramientas/calculadora-sueldo-neto/#tabla_resultados.