



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Facultat d'Informàtica de Barcelona



Informe Final de Pràctiques Curriculars

POL CASACUBERTA GIL

Facultat d'Informàtica de Barcelona (FIB)

Universitat Politècnica de Catalunya (UPC) - BarcelonaTech

Contents

1	Objectius del projecte	3
2	Descripció de les tasques realitzades	3
2.1	projecte poblacions amb R	3
2.2	Projecte Fuzzy Matching	4
2.3	Extraccions de dades	5
2.3.1	Metodologia d'extracció:	5
2.3.2	Desafiaments en l'Extracció de dades	6
3	Desviacions sobre la planificació	6
4	Observacions	6
4.1	Comunicació amb el responsable	6
4.2	Inici de les pràctiques amb un altre intern	7

1 Objectius del projecte

El present projecte s'ha concebut com a part integral de les meves pràctiques universitàries, amb l'objectiu de posar en pràctica els coneixements adquirits durant el meu curs acadèmic en la Facultat d'Informàtica de Barcelona a la UPC, així com adquirir noves competències en el marc de la gestió de bases de dades i l'analítica de dades en un context empresarial real. Els objectius específics del projecte són:

- Aplicar coneixements teòrics en un entorn professional: Demostrar la capacitat d'aplicar els principis teòrics de les bases de dades, programació i analítica de dades en la solució de problemes reals dins de l'empresa, particularment en l'àmbit de les assegurances.
- Desenvolupar habilitats tècniques específiques: Adquirir i millorar habilitats tècniques en l'ús de llenguatges de programació com SQL, R i PowerShell, així com en el disseny, normalització i gestió de bases de dades.
- Implementar solucions a desafiaments reals de l'empresa: Contribuir de manera efectiva a la resolució de problemes específics de l'empresa, com l'actualització i manteniment de bases de dades, i processos d'extracció de dades per a processos interns i externs de l'empresa.
- Fomentar el desenvolupament professional i personal: A través de la realització d'aquest projecte, buscar el creixement personal i professional, desenvolupant una actitud proactiva, capacitat d'aprenentatge autònom i habilitats de treball en equip.

Aquest projecte representa una oportunitat per integrar els coneixements teòrics amb l'experiència pràctica, permetent-me no només comprendre millor els desafiaments reals als quals s'enfronten els professionals en el camp de les TI, sinó també contribuir de manera significativa a l'empresa durant les meves pràctiques.

2 Descripció de les tasques realitzades

2.1 projecte poblacions amb R

Aquest projecte té com a objectiu l'actualització de les adreces de domicilis de MGS. El que es vol saber és quins codis postals cauen dins d'un municipi concret. Els municipis estan identificats de manera única pel codi INE. Per aconseguir això ho hem fet de la següent manera:

- Recollida de dades: Vam obtenir la geometria de cada codi postal des d'un repositori i la geometria de cada municipi d'Espanya a través de la web del Centro Nacional de Información Geográfica.

- Anàlisi geoespacial: Un cop tenim les geometries dels codis postals i de la geometria dels municipis, podem saber quins codis postals cauen en un municipi concret aplicant la intersecció. Fem servir un llindar basat en el percentatge d'intersecció. Si A = codis postals i B = Municipis llavors podem extreure les següents fórmules:

$$\text{Percentatge de A en B} = \left(\frac{|A \cap B|}{|A|} \right) \times 100$$

Això voldria dir que un x % de l'àrea del codi postal està dins del municipi

$$\text{Percentatge de intersecció de B en A} = \left(\frac{|A \cap B|}{|A|} \right) \times 100$$

Això vol dir que un x % del municipi està cobert per l'àrea del codi postal

- Visualització de dades: Vam utilitzar la llibreria leaflet per crear mapes interactius que facilitessin la visualització de les àrees de codis postals i poblacions, millorant així la validació dels resultats.

2.2 Projecte Fuzzy Matching

El projecte Fuzzy Matching va ser dissenyat amb l'objectiu d'abordar el desafiament de normalitzar i actualitzar els noms dels carrers registrats en les bases de dades de MGS. Aquesta necessitat sorgeix a causa de la variabilitat amb què els usuaris introdueixen els noms dels carrers, incloent-hi diferents idiomes, abreviatures i errors ortogràfics, que poden complicar les tasques d'anàlisi i consulta de dades. La finalitat era millorar la consistència i l'exactitud de les dades per facilitar processos interns i millorar la qualitat de servei al client.

Fent servir tècniques de fuzzy matching es vol emparellar els noms introduïts pels usuaris amb els noms oficials del Catastro.

- Exploració de Mètriques de distància: Es van explorar les possibles mètriques per avaluar la seva eficàcia en el context dels noms de carrers. Aquestes inclouen:
 - Levenshtein
 - Damerau-Levenshtein
 - Jaro-Winkler
 - Q-Gram
 - Subseqüència comuna més llarga (LCS)
 - Distància de Hamming
 - Distància de Jaccard i Cosinus basadas en perfils Q-Gram
- Obtenció de dades: Es va desenvolupar un script per a obtenir dades concretes de certes poblacions des de l'API del Catastro per a poder fer proves reals, junt amb les dades de MGS.

- Desenvolupament de l'script de comparació: Vem programar un script en R que comparava noms de carrers tant de MGS com del Catastro utilitzant mètriques de distància seleccionades per determinar el millor emparellament.
- Optimització de l'emparellament: En la versió final del script vam utilitzar una combinació de diverses mètriques ponderades com Damerau-Levenshtein i Q-Gram:
 - Es crea una matriu de distàncies entre cada parell de noms de carrers utilitzant les mètriques seleccionades.
 - Apliquem una fórmula combinada de distàncies per identificar el millor emparellament entre els noms de carrers de les dues fonts.
- Avaluació i ajustament: Es va procedir a l'ajustament de pesos dins de la fórmula combinada de distàncies, per equilibrar l'impacte de les dues mètriques principals.

2.3 Extraccions de dades

Dins dels projectes assignats durant el meu període de pràctiques, una tasca fonamental va ser l'extracció de dades de les bases de dades SQL de MGS. Aquest procés va ser essencial per obtenir la informació requerida per a processos tant per a clients interns com externs de l'empresa. Les extraccions es basen en recuperar dades específiques de les taules, assegurant que la informació estigui correctament formatejada per al seu ús posterior.

2.3.1 Metodologia d'extracció:

La metodologia per a l'extracció de dades va seguir un enfocament estructurat i sistemàtic. Aquest procés va incloure:

- Definició de requeriments: Identificació precisa de les dades necessàries, incloent-hi camps específics i criteris de filtratge.
- Consulta SQL avançada: Utilització de consultes SQL complexes per extreure dades de múltiples taules i vistes, emprant tècniques com joins, subconsultes, funcions d'agregació i fins i tot SQL dinàmic per recopilar la informació desitjada.
- Formateig de dades: Transformació de les dades extretes per complir amb els formats requerits per les anàlisis o aplicacions posteriors. Això inclou la normalització de formats de text i data i l'estructuració de dades en formats específics com CSV per a la seva exportació.

2.3.2 Desafiaments en l'Extracció de dades

Els desafiaments enfrontats durant les extraccions van incloure el maneig de grans volums de dades, i el desconeixement del negoci i l'estructura de les taules de dades dificulta el saber a on s'han d'anar a buscar les dades. També optimitzar les consultes per millorar el rendiment i reduir el temps d'execució.

3 Desviacions sobre la planificació

Durant el desenvolupament del projecte, una de les principals preocupacions era mantenir-nos fidels a la planificació inicial, assegurant-nos que tots els objectius es complissin dins dels terminis establerts. Finalment les desviacions respecte a la planificació original van ser mínimes.

Les raons darrere la falta de desviacions poden atribuir-se a diversos factors:

- Definició clara d'objectius: Els objectius del projecte van ser definits de manera precisa des de l'inici, el que va permetre una planificació acurada.
- Flexibilitat en la planificació: tot i que la planificació inicial era detallada, també va permetre espai per a la flexibilitat, permetent adaptar-se a petits imprevistos sense que afectessin el pla general.
- Comunicació constant i efectiva: La comunicació entre tots els membres de l'equip va ser constant, el que va facilitar la resolució ràpida de qualsevol dubte o contratemps que pogués sorgir.

La desviació més gran que va haver-hi va ser en una de les extraccions de Pricing on es va haver de reformular l'extracció per part del client intern, ja que va haver un canvi en les necessitats.

4 Observacions

Durant el transcurs de les pràctiques, hi ha hagut diverses observacions notables que han contribuït significativament a l'experiència d'aprenentatge i al desenvolupament professional dins de l'empresa. Entre aquestes, dues en particular mereixen ser destacades:

4.1 Comunicació amb el responsable

Una de les claus del progrés durant el període de pràctiques ha estat la facilitat i obertura per a la comunicació amb el meu responsable. Aquesta accessibilitat ha estat essencial per aclarir dubtes, rebre orientació i feedback constructiu, així com per adaptar-me ràpidament a l'entorn de treball i a les expectatives del projecte.

4.2 Inici de les pràctiques amb un altre intern

Començar les pràctiques al costat d'un altre intern va resultar ser una experiència molt positiva. Aquesta situació va oferir l'oportunitat de compartir dubtes, aprendre de manera col·laborativa i donar suport mutu en els reptes que es presentaven. Treballar conjuntament va facilitar una adaptació més ràpida a l'entorn de treball i va permetre el desenvolupament de solucions creatives.

A més, la presència d'un altre intern va afavorir un intercanvi de coneixements i experiències que va enriquir la meva estada a l'empresa, contribuint a una visió més àmplia de les pràctiques professionals i fomentant un sentiment de companyerisme i suport dins de l'equip de pràctiques.