



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Facultat d'Informàtica de Barcelona



GENERACIÓN DE DATOS ARTIFICIALES PARA MODELOS DE APRENDIZAJE PROFUNDO EN IMAGEN MÉDICA

POL CASACUBERTA GIL

Entrega 1: Contextualización y alcance

Tutor GEP: Carolina Consolación

Director/a: JAVIER BÉJAR ALONSO (Departamento de Ciencias de la

Computación) **Titulación:** Grado en Ingeniería Informática (Computación)

Memoria del trabajo de fin de grado

Facultat d'Informàtica de Barcelona

(FIB)

Universitat Politècnica de Catalunya (UPC) - BarcelonaTech

Índice

1. Introduccion	3
2. Contexto	3
2.1. Centrar el proyecto en el marco de la FIB	3
2.2. Definición de conceptos	3
2.2.1. Datos artificiales	3
2.2.2. VAE	4
2.2.3. GAN	5
2.2.4. Modelo de difusión	5
2.3. Identificación del problema a resolver	6
2.4. Actores implicados	6
3. Justificación	7
4. Alcance	7
4.1. Objetivos del proyecto	7
4.1.1. Subobjetivos	8
4.2. Identificar otros requerimientos funcionales o no funcionales . . .	8
4.2.1. Requerimientos funcionales	8
4.2.2. Requerimientos no funcionales	9
4.3. Obstáculos y riesgos	9
4.3.1. Obstáculos técnicos	9
4.3.2. Obstáculos Médicos	9
4.3.3. Riesgos de Ética y privacidad	10
4.3.4. Riesgos de Evaluación de resultados	10
4.3.5. Riesgos de Recursos	10
5. Metodología y rigor	10
5.1. Metodología	10
5.2. Metodología del desarrollo de código	11

1. Introduccion

La detección temprana de anomalías o características dentro de imágenes es una tarea crítica en diversos campos, desde la imagen médica hasta la visión por computador y más allá. En este contexto, el desarrollo y la exploración de modelos generativos basados en la traducción de imagen a imagen han surgido como un enfoque poderoso para abordar este desafío. Este proyecto tiene como objetivo investigar y desarrollar modelos de aprendizaje profundo generativos para la traducción de imagen a imagen, con un enfoque en su aplicación a conjuntos de datos, donde la generación de datos sintéticos puede mejorar el entrenamiento de modelos de aprendizaje profundo para diversas tareas.

La traducción de imagen a imagen se refiere al proceso de transformar una imagen de un dominio o estilo en otro, preservando al mismo tiempo las características esenciales e información. Esta técnica versátil ha encontrado aplicaciones en numerosos campos. Un ejemplo destacado de ello es la transferencia de estilo artístico, tal como se presenta en el trabajo de Jing et al. [2]. Además, también se ha utilizado en la mejora de la resolución de imágenes, como se discute en [4], y en la restauración de imágenes, entre otros usos.

Al aprovechar las capacidades de los modelos generativos, podemos generar datos sintéticos que complementan conjuntos de datos existentes, abordando así limitaciones relacionadas con la escasez, diversidad o calidad de los datos.

En este caso, utilizaremos el conjunto de datos LDPolypVideo [5], que consiste en videos de colonoscopias y contiene máscaras que serán utilizadas para entrenar los modelos.

En las secciones siguientes, profundizaremos en los objetivos específicos y las metodologías de esta iniciativa de investigación.

2. Contexto

2.1. Centrar el proyecto en el marco de la FIB

Este trabajo de fin de grado de Ingeniería informática se sitúa en el marco de la Facultad de informática de Barcelona de la Universidad Politécnica de Cataluña y está dirigido por Javier Béjar Alonso. Esta investigación también se enmarca dentro del BSC en el grupo de investigación HPAI.

2.2. Definición de conceptos

2.2.1. Datos artificiales

Para abordar un problema de segmentación de imágenes necesitamos un dataset anotado, en cuyo caso las imágenes del dataset deben ser anotadas manualmente, conseguir que esta segmentación manual sea perfecta a nivel de pixel para tantas imágenes no es tarea fácil, suele ser un trabajo muy costoso. Cuál es la solución? Ahí es donde entra la síntesis de datos artificiales. Generamos mediante diferentes tipos de técnicas unos datos parecidos a los originales, pero

suficientemente diferentes como para que se mejore la robustez de nuestra red de segmentación de imágenes. [7]

A continuación hablaremos de algunas arquitecturas que se pueden usar para generar imágenes sintéticas.

2.2.2. VAE

Las estructuras Variational auto-encoding se han usado con éxito para segmentar imágenes, como se hace en UNet-eVAE [6].

Un VAE es una red neuronal que usamos para aprender y generar datos como imágenes o texto. El objetivo principal del VAE es capturar y modelar una distribución de probabilidad usando los datos en la entrada, generando con estos datos otros nuevos que sean similares a la entrada.




Figura 1: Diagrama de los componentes de un VAE.

Fuente: By EugenioTL - Own work, CC BY-SA 4.0,
<https://commons.wikimedia.org/w/index.php?curid=107231104>

Componentes del VAE:

- Encoder o *Approximate Posterior*: En la primera parte de un VAE, llamada codificación, se toma una entrada y se mapea a un espacio latente, es decir, una representación en baja dimensión que captura las características importantes de los datos.
- Espacio latente: Este espacio latente se corresponde con los parámetros de una distribución variacional, de esta manera el encoder puede producir diferentes muestras que provienen de la misma distribución.
- Decoder: Esta parte del VAE tiene la función opuesta al Encoder, mapea desde el espacio latente al espacio del input para producir datos.

Ambas redes se entrenan de forma conjunta utilizando el truco de la reparametrización. Se explica con más detalle en [3].

2.2.3. GAN

Las Redes Generativas Adversarias o GAN, son una clase de modelos de aprendizaje automático utilizados en el aprendizaje no supervisado. Fueron introducidas por Ian Goodfellow [1].

Las GAN están compuestas de dos redes neuronales: el Generador y el Discriminador, que se entrenan generalmente de forma alterna, durante unas Epochs, se entrena el Generador y en otras el Discriminador.




Figura 2: Diagrama de los componentes de una GAN.

Fuente: [10]

- Generador: El propósito de la red Generador es crear datos falsos, generalmente imágenes, que se parezcan a los datos reales. Toma ruido aleatorio como entrada, aunque también existen variaciones que toman otros tipos diferentes de input.
- Discriminador: La red discriminadora va a ser la encargada de distinguir los datos reales (imágenes reales) de los ficticios (generados por el generador). El discriminador se entrena con un conjunto de datos que contiene ejemplos reales o *ground truth*.

2.2.4. Modelo de difusión

Los modelos de difusión se basan en los principios de la termodinámica de sistemas fuera de equilibrio. Estos modelos establecen una secuencia de pasos de difusión que gradualmente introducen ruido aleatorio en los datos y luego se capacitan para deshacer este proceso de difusión. Esto les permite generar muestras de datos a partir del ruido. En contraste con los VAE (Autoencoders Variacionales), los modelos de difusión emplean un procedimiento fijo de aprendizaje, y la variable latente tiene una alta dimensionalidad, equivalente a la de los datos originales.




Figura 3: Resumen de los diferentes tipos de modelos generativos incluidos los modelos de diffusion.

Fuente: [8]

2.3. Identificación del problema a resolver

El proyecto se inicia con la identificación de un problema que se abordará utilizando modelos generativos de traducción de imagen a imagen. En este contexto, el problema identificado es la limitación de datos de entrenamiento de alta calidad y diversidad, esta situación suele ser común en el campo médico, ya que obtener datos resulta costoso debido a cuestiones como la privacidad y los gastos asociados con la obtención de datos anotados. Incluso cuando contamos con datos anotados, a menudo los profesionales de la salud se enfrentan a dificultades para emitir diagnósticos precisos en ciertos casos.

Este proyecto se enfocará en desarrollar y evaluar modelos generativos, eficientes y efectivos para resolver estos desafíos en un contexto específico, lo que contribuirá a abordar un problema común en diversas áreas de la inteligencia artificial y la ciencia de datos.

2.4. Actores implicados

- **Estudiante investigador:** el estudiante que realiza el proyecto es un stakeholder clave, ya que su trabajo conllevará aprender sobre una variedad de disciplinas a lo largo del proyecto.
- **Director del trabajo:** Es quien supervisa y guía al estudiante en el proyecto, este también es esencial en el proyecto. Su experiencia y orientación afectará en el desarrollo y la calidad del proyecto.
- **Universidad:** A la institución académica le es de su interés que los proyectos llevados a cabo por los alumnos tengan éxito, ya que contribuyen a la reputación de la misma.

- Comunidad científica: Otros investigadores y académicos en el campo de la informática, la visión por computador y la inteligencia artificial son stakeholders relevantes. Los avances y descubrimientos que surgen del proyecto pueden contribuir al conocimiento.
- Pacientes: Dado que estamos tratando con aplicaciones del ámbito médico, los pacientes o la población se pueden beneficiar de las mejoras en detección de enfermedades, como la detección temprana de pólipos, estos son stakeholders cruciales.
- Profesionales de la Salud: Los médicos y profesionales de la salud que utilizan las herramientas basadas en el proyecto para mejorar el diagnóstico, son stakeholders importantes. El buen rendimiento de estas herramientas de diagnóstico puede mejorar la calidad de la atención médica.

3. Justificación

La elección de entrenar nuestras propias Redes neuronales en el Barcelona SuperComputing Center (BSC) utilizando el dataset proporcionado, se basa en una evaluación específica de las necesidades y objetivos de nuestro proyecto.

En el ámbito de la generación de imágenes médicas, los requisitos de precisión y especificidad son críticos. Las redes generativas preentrenadas pueden ser una opción viable, pero al diseñar y entrenar nuestras propias redes generativas, tenemos un mayor control sobre la adaptación de los modelos a las características únicas de nuestro conjunto de datos. Un ejemplo de redes generativas preentrenadas son las que brindan medigan [9] con redes preentrenadas para segmentar pólipos.

Entrenar nuestras propias redes generativas nos permite personalizar los modelos para satisfacer las demandas específicas de nuestro proyecto. Podemos ajustar la arquitectura de las redes, los hiperparámetros y las técnicas de entrenamiento para optimizar la generación de imágenes médicas de alta calidad. El dataset en cuestión puede tener características particulares que requieran una adaptación cuidadosa. Entrenar nuestras propias redes generativas en el BSC nos brinda la potencia de cálculo necesaria para abordar estos desafíos. Otro factor a tener en cuenta es la propiedad intelectual. Entrenar nuestras propias redes generativas nos otorga la propiedad intelectual completa.

4. Alcance

4.1. Objetivos del proyecto

- Segmentar los pólipos de las imágenes.
- Crear una interfaz gráfica

4.1.1. Subobjetivos

- Escoger métricas de evaluación.
- Ajustar hiperparámetros.
- Diseñar la arquitectura de la red neuronal.
- Entrenar una red neuronal que segmente los pólipos de las imágenes.
- Entrenar una red neuronal que genere datos artificiales.
- Entrenar una red neuronal con los datos artificiales y los reales.
- Entrenar una red neuronal con los datos artificiales.
- Reajustar la red neuronal entrenada con los datos reales solo con datos artificiales.
- Reajustar la red neuronal entrenada con los datos reales con una combinación de datos artificiales y reales.
- Entrenar una red con datos artificiales y ajustar la red con datos reales.
- Usar modelos que generan directamente tanto imágenes como mascararas.

4.2. Identificar otros requerimientos funcionales o no funcionales

4.2.1. Requerimientos funcionales

- Captura de datos de Video: el sistema debe ser capaz de recibir y procesar videos de colonoscopias como entrada.
- Segmentación de imágenes: El sistema debe ser capaz de segmentar las imágenes de los videos para identificar áreas relevantes.
- Generación de informes: El sistema debe ser capaz de generar informes que evalúen la calidad de las segmentaciones.
- Interfaz de Usuario: El sistema debe tener una interfaz de usuario que permita interactuar con él de manera intuitiva.
- Documentación: Debe proporcionarse documentación detallada para usuarios y profesionales médicos.

4.2.2. Requerimientos no funcionales

- Eficiencia Computacional.
- Escalabilidad: Si se prevé el uso en el futuro, es posible que haya la necesidad de gestionar un volumen más grande de datos de entrenamiento.
- Robustez: Establecer la capacidad del modelo para afrontar situaciones inesperadas o ataques adversos como la manipulación de los datos de entrada para estimular las neuronas de tal manera que se obtengan resultados diferentes a los que esperaríamos con el input dado. Por ejemplo, en un modelo para segmentar pólipos en imágenes, un atacante podría camuflar pólipos en las imágenes para que no sean detectados o perturbar una imagen donde no hay pólipos con perturbaciones imperceptibles para los humanos, pero que el modelo detecte que hay pólipos.
- Tiempo de inferencia.
- Documentación y mantenimiento.
- Identificar y definir los posibles obstáculos y riesgos.
- Explorar y seleccionar las arquitecturas de los modelos que se adapten mejor al problema que se está tratando.
- Los tiempos de entrenamiento de los datos pueden llegar a ser prohibitivos debido a la gran cantidad de datos y a la complejidad de las arquitecturas.
- Colaboración interdisciplinaria.

4.3. Obstáculos y riesgos

4.3.1. Obstáculos técnicos

- Mode collapse, es un problema común cuando entrenamos (GANs) y se refiere a cuando la red produce un número limitado o similar de outputs, esto suele suceder cuando la parte generadora de la red produce un resultado realista, puede ser que este aprenda a producir outputs iguales o similares a ese para engañar al discriminador.
- La selección de los hiperparámetros puede ser complicada y puede dar a entrenamientos ineficientes y rendimientos deficientes.
- Tiempos de entrenamiento prolongados: Los modelos generativos a menudo requieren tiempos de entrenamiento largos, especialmente en conjuntos de datos grandes, lo que puede ser costoso en términos de tiempo, y recursos computacionales.

4.3.2. Obstáculos Médicos

- Regulaciones Médicas: Se deben cumplir con regulaciones médicas y de privacidad de datos. Cumplir con estas regulaciones puede ser un desafío.

4.3.3. Riesgos de Ética y privacidad

- Privacidad de los Pacientes: La gestión de datos médicos sensibles debe cumplir con los estándares éticos y de privacidad de datos.
- Sesgo y Equidad: Los modelos de aprendizaje profundo pueden tener sesgos inherentes. Identificar y mitigar el sesgo es esencial para garantizar la equidad en la detección.

4.3.4. Riesgos de Evaluación de resultados

- Errores de Falsos Positivos/Negativos: Los errores en la detección de pólipos pueden tener graves implicaciones médicas. Reducir estos errores es importante.
- Sobreajuste de los modelos: El modelo podría sobreajustarse a los datos de entrenamiento y no generalizar bien a nuevos datos.
- Métricas inadecuadas: Utilizar métricas inadecuadas para evaluar la calidad de las generaciones puede llevar a conclusiones erróneas sobre el rendimiento del modelo.
- Interpretabilidad: Interpretar, explicar los resultados de los modelos generativos no es trivial, entender qué características está buscando el modelo para discriminar el resultado puede ser difícil.

4.3.5. Riesgos de Recursos

- Tiempo: el tiempo requerido para completarse el proyecto se podría prolongar.

5. Metodología y rigor

5.1. Metodología

El desarrollo de este trabajo va a estar basado en gran parte a una investigación empírica donde se van a probar un gran número de arquitecturas, hiperparámetros y metodologías para atacar el problema en cuestión para posteriormente evaluar cuáles son las mejores configuraciones. Por este motivo y por ser un proyecto de un solo autor, se va a utilizar una metodología ágil que va a permitir modificar el plan de trabajo, en concreto se va a utilizar Kanban. El Kanban típicamente consiste en tres columnas:

- To-do: Tareas que hay que hacer, pero que aún no han empezado.
- En progreso: Son las tareas en las que se está trabajando de forma activa.
- Done: Cuando una tarea en progreso se acaba, se mueve a esta columna

La idea principal del Kanban es visualizar las tareas y limitar la cantidad de trabajo en progreso.

Además, se programarán entrevistas semanales con el director del proyecto para evaluar el trabajo hecho durante la semana y hablar sobre la dirección que tiene que tomar el trabajo.

5.2. Metodología del desarrollo de código

Para llevar un control de versiones del código que se va generando durante el curso del proyecto se va a usar Git, un software ya muy conocido para controlar los cambios en el código de forma cómoda y eficiente.

El código que se va generando, para ser más fácilmente accesible y para evitar imprevistos con el disco local, se va a subir a un repositorio en el servicio web GitHub.

En cuanto al flujo de trabajo que se va a utilizar, será el Git Flow, donde hay las siguientes ramas:

- Master: Contiene el código en producción. Todo el código de desarrollo se fusiona en esta rama en algún momento a través de las releases.
- Develop: Contiene el código en preproducción, cuando se quiere finalizar un feature, se fusiona con esta rama.
- Feature: Por cada tarea que se realiza, se crea una nueva rama para trabajar en ella. Esta rama parte de develop.
- Hotfix: Se encarga de corregir una incidencia. Parte de develop.
- Releases: Parte de develop. Se fusionará con la rama master.

Con el objetivo de ser pragmáticos se usarán principalmente las ramas master y develop, ya que al ser una única persona en el proyecto será más ágil.

Referencias

- [1] Ian J. Goodfellow et al. *Generative Adversarial Networks*. 2014. arXiv: 1406.2661 [stat.ML].
- [2] Yongcheng Jing et al. *Neural Style Transfer: A Review*. 2018. arXiv: 1705.04058 [cs.CV].
- [3] Diederik P. Kingma y Max Welling. “An Introduction to Variational Autoencoders”. En: *Foundations and Trends® in Machine Learning* 12.4 (2019), págs. 307-392. DOI: 10.1561/22000000056. URL: <https://doi.org/10.1561%2F22000000056>.
- [4] Sumit Dhawan y Shailender Kumar. “Improving resolution of images using Generative Adversarial Networks”. En: *2020 4th International Conference on Electronics, Communication and Aerospace Technology (ICECA)*. 2020, págs. 880-887. DOI: 10.1109/ICECA49313.2020.9297414.
- [5] Yiting Ma et al. *LDPolypVideo Benchmark: A Large-Scale Colonoscopy Video Dataset of Diverse Polyps*. Ene. de 2021. URL: https://link-springer-com.recursos.biblioteca.upc.edu/chapter/10.1007/978-3-030-87240-3_37.
- [6] Soumya Gupta et al. “UNet-eVAE: Iterative Refinement Using VAE Embodied Learning for Endoscopic Image Segmentation”. En: *Machine Learning in Medical Imaging*. Ed. por Chunfeng Lian et al. Cham: Springer Nature Switzerland, 2022, págs. 161-170. ISBN: 978-3-031-21014-3.
- [7] James Jordon et al. *Synthetic Data – what, why and how?* 2022. arXiv: 2205.03257 [cs.LG].
- [8] ifttt-user. *Diffusion Models vs. GANs vs. VAEs: Comparison of Deep Generative...* Mayo de 2023. URL: <https://towardsai.net/p/machine-learning/diffusion-models-vs-gans-vs-vaes-comparison-of-deep-generative-models>.
- [9] Richard Osuala et al. “medigan: a Python library of pretrained generative models for medical image synthesis”. En: *Journal of Medical Imaging* 10.06 (feb. de 2023). DOI: 10.1117/1.jmi.10.6.061403. URL: <https://doi.org/10.1117%2F1.jmi.10.6.061403>.
- [10] En: *Google for Developers* (). URL: https://developers.google.com/machine-learning/gan/gan_structure.